



学校代码: 10286

分类号: TP181

密 级: 公开

U D C: 004.8

学 号: 211923

基于规则演化的多智能体博弈对抗策略

李萱露

东南大学



东南大学 电子信息硕士学位论文

基于规则演化的 多智能体博弈对抗策略

研究生姓名: 李萱露

导师姓名: 张亚 教授

崔鹏 高工

申请学位类别 电子信息硕士 学位授予单位 东南大学

领域名称 控制工程 论文答辩日期 2024 年 5 月 21 日

研究方向 多智能体博弈对抗策略 学位授予日期 2024 年 月 日

答辩委员会主席 翟军勇 教授 评 阅 人 YS008240107

YS008240108

2024 年 5 月

心於至善



SOUTHEAST UNIVERSITY

東南大學

硕士学位论文

基于规则演化的
多智能体博弈对抗策略

专业名称: 电子信息

研究生姓名: 李萱露

导师姓名: 张亚 教授

MULTI-AGENT GAME ADVERSARIAL STRATEGIES BASED ON RULE EVOLUTION

A Thesis Submitted to

Southeast University

For the Academic Degree of Master of Engineering

BY

Li Xuanlu

Supervised by

Prof. Zhang Ya

School of Automation

Southeast University

May 2024

东南大学学位论文独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

研究生签名：_____日期：_____

东南大学学位论文使用授权声明

东南大学、中国科学技术信息研究所、国家图书馆有权保留本人所送交学位论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括以电子信息形式刊登）论文的全部内容或中、英文摘要等部分内容。论文的公布（包括以电子信息形式刊登）授权东南大学研究生院办理。

研究生签名：_____导师签名：_____日期：_____

摘要

随着军事科技的发展和现代战争的复杂化，人工智能技术的引入对军事决策具有重要意义。然而，深度神经网络的“黑盒”特性，使得模型可解释性成为广泛研究的议题。因此本文以规则演化理论为基础，结合军事博弈现实需求，以知识和数据相结合的训练方法进行多智能体策略学习，并应用于典型复杂博弈对抗场景中。论文的主要研究工作如下：

一、针对多智能体博弈对抗场景中智能体决策模型的解释性问题，设计了一种基于学习分类器系统的智能体决策模型。该模型由分类器子系统和规则发现子系统组成，其中分类器子系统采用规则的方式实现智能体决策，规则发现子系统提高规则库的多样性；同时设计了规则评估机制指导模型学习。在空战博弈场景下，该模型提高了智能体对抗性能，模型本身具有较强的解释性。

二、针对深度强化学习模型生成的策略解释性差的问题，提出一种基于规则的策略提取与解释深度强化学习模型策略的方法。使用强化学习模型进行博弈对抗生成对抗数据，基于对抗数据采用策略提取方法将强化学习模型策略提取成一个决策树策略，通过决策树解释方法进行规则提取进而实现模型的可解释性。在典型博弈对抗场景下，提取出的决策树模型在对抗效能上能完全替代强化学习模型，并在对抗胜率上有一定提高。此外，针对两种对抗环境，提取决策树中的策略规则，构建策略规则库，建立博弈对抗策略决策树。

三、为了获得更多的博弈对抗策略，将提取出的决策树模型作为专家决策树，设计一种基于遗传算法的决策树演化方法，利用遗传算法进行解空间的探索，以增强决策的多样性，实现知识与数据协同驱动。在典型博弈对抗场景下，经演化后的决策树在对抗效能方面都有不同程度的提升，通过对决策树的规则提取与分析，获得新增的策略规则表，进一步充实博弈对抗策略。

关键词：多智能体，规则学习，决策树，遗传算法，博弈对抗

Abstract

With the development of military technology and the increasing complexity of modern warfare, the introduction of artificial intelligence (AI) technology is of great significance to military decision-making. However, the "black box" characteristic of deep neural networks has made model interpretability an important issue. Therefore, the strategy learning problem in the multi-intelligence game confrontation scenario is investigated in this paper. Based on the rule evolution theory, combined with the real needs of military gaming, this paper uses a training method that combines knowledge and data and applies it to complex game confrontation scenarios to verify its effectiveness.

The main research contents of the thesis are as follows:

Firstly, a decision-making model for intelligent agents based on a learning classifier system is designed to address the interpretability issue of decision models in multi-agent adversarial scenarios. This model consists of two subsystems: a classifier subsystem and a rule discovery subsystem. The classifier subsystem employs rules to determine the decisions of the intelligent agents, while the rule discovery subsystem enhances the diversity of the rule set. Additionally, a rule evaluation mechanism has been designed to guide model learning. In the context of aerial combat gaming scenarios, this model has demonstrated improvements in the combat performance of intelligent agents while also possessing strong interpretability.

Secondly, a method based on rule-based policy extraction and interpretation for deep reinforcement learning (DRL) model policies is proposed to address the problem of poor interpretability of DRL strategies. By utilizing reinforcement learning model policies in adversarial gaming scenarios to generate adversarial data, a policy extraction method is employed to extract the reinforcement learning model policy into a decision tree policy. This decision tree policy is then interpreted using decision tree interpretation methods to extract rules, thereby achieving model interpretability. In the context of dual-ship anti-air warfare scenarios, the extracted decision tree model completely replaces the DRL model in terms of operational efficacy, with a notable improvement in the win rate during battles. Additionally, tactical rules are extracted from the decision tree to construct a tactical rule repository, facilitating the establishment of adversarial gaming strategies in two combat environments.

Thirdly, in order to obtain a broader range of adversarial gaming strategies, the extracted decision tree model is utilized as an expert decision tree, and a decision tree evolution method based on genetic algorithm is designed to realize the collaborative driving of knowledge and data. This approach utilizes genetic algorithms to explore solution spaces, thereby enhancing the diversity of decision-making. In the context of dual-ship anti-air warfare scenarios, the evolved decision trees exhibit varying degrees of improvement in operational efficacy. By extracting and analyzing rules from the decision trees, a new set of tactical rules is obtained, further enriching the repertoire of adversarial gaming strategies.

Keywords: multi-agent, rule learning, decision tree, genetic algorithm, game confrontatio

目录

摘要	I
Abstract	III
目录	V
第一章 绪论	1
1.1 研究背景	1
1.2 国内外研究现状	2
1.2.1 多智能体博弈对抗策略研究现状	2
1.2.1.1 基于专家系统的方法	2
1.2.1.2 基于群体智能的方法	3
1.2.1.3 基于遗传及进化算法的方法	4
1.2.1.4 基于神经网络和强化学习的方法	5
1.2.2 规则学习研究现状	6
1.2.2.1 学习分类器	7
1.2.2.2 决策树及优化	8
1.3 论文研究内容	9
1.4 论文组织结构	10
第二章 预备知识	13
2.1 规则学习相关理论	13
2.1.1 学习分类器	13
2.2 决策树相关知识	14
2.2.1 决策树生成	15
2.2.2 划分标准及算法	16
2.3 遗传算法相关知识	18
2.3.1 遗传算法基本概念	18
2.3.2 遗传算法的五个基本环节	20
2.4 本章小结	22
第三章 基于学习分类器系统的智能体决策模型	23
3.1 引言	23
3.2 问题描述	23
3.2.1 联合对抗智能博弈对抗平台简介	23
3.2.2 实验场景	25
3.3 博弈对抗策略模型设计	26
3.3.1 分类器子系统设计	27
3.3.2 规则发现子系统设计	28

3.3.2.1 选择算子	28
3.3.2.2 交叉算子	29
3.3.2.3 变异算子	29
3.3.3 规则评估机制设计	29
3.3.3.1 实时更新机制	30
3.3.3.2 全局回报分配机制	30
3.4 实验与分析	31
3.4.1 实验结果	31
3.5 本章小结	33
第四章 基于规则的策略提取与解释深度强化学习模型	35
4.1 引言	35
4.2 问题描述	35
4.3 策略提取与规则解释	36
4.3.1 强化学习模型介绍	37
4.3.2 基于 Viper 算法的决策树构建	38
4.3.3 决策规则提取	40
4.4 实验与分析	41
4.4.1 实验场景	41
4.4.2 实验内容	41
4.4.2.1 博弈对抗数据预处理	41
4.4.2.2 基于规则的策略提取和解释强化学习模型	42
4.4.3 实验一结果	43
4.4.3.1 策略有效性	43
4.4.3.2 策略解释性	44
4.4.4 实验二结果	47
4.4.4.1 策略有效性	47
4.4.4.2 策略解释性	48
4.5 本章小结	50
第五章 基于遗传算法的决策树演化	51
5.1 引言	51
5.2 问题描述	51
5.3 决策树演化设计	51
5.3.1 染色体编码与种群初始化	52
5.3.2 遗传操作设计	52
5.3.2.1 选择算子	52
5.3.2.2 交叉算子	52
5.3.2.3 变异算子	53

5.3.3 决策树评估机制	54
5.3.3.1 实时更新机制	55
5.3.3.2 全局对抗结果评估机制	55
5.4 实验与分析	55
5.4.1 实验参数设定	56
5.4.2 策略有效性	56
5.4.3 策略提取效果对比	59
5.4.3.1 实验一	59
5.4.3.2 实验二	61
5.5 本章小结	62
第六章 总结与展望	63
6.1 全文总结	63
6.2 讨论与展望	63
致谢	65
参考文献	67
作者简介	73

第一章 绪论

1.1 研究背景

当代战争环境下，随着军事科技的迅速发展和现代战争的快节奏、高复杂性等特点日益凸显，对抗过程中对军事指挥决策提出了更高的要求，传统的人脑决策方式在面对信息快速更迭的挑战时已显得力不从心。因此，引入人工智能（Artificial Intelligence, AI）技术对于提升指挥部的决策速度、现代军队的反应打击能力以及各军种的协同配合水平具有重要意义^[1]。人工智能技术可以有效地降低人工成本，为军事指挥提供更系统、科学、全面的指导方案。利用大数据分析、智能决策支持系统等技术手段，军事指挥部能够更准确地把握战场态势，做出迅速而精准的决策；现代军队可以更迅速地响应和打击敌对行动；各军种之间也能够更加高效地协同对抗，提高整体对抗效能。

智能博弈对抗技术在现代军事智能化中发挥着关键作用^[2]。现代战争已经变成了高度信息化、数字化的多智能体系统，各个对抗单位之间通过信息交流和相互作用形成复杂的网络结构^[3]。在这个背景下，智能博弈对抗技术通过深度学习和强化学习等前沿人工智能技术的应用，实现了对庞大、复杂对抗数据的智能处理和分析。深度学习通过神经网络模型学习样本数据的隐含特征，提取战场态势中的关键信息。强化学习则使智能体能够在与环境交互中自主学习和优化行动策略。通过模拟智能体与战场环境的交互关系并设计奖励机制，强化学习使军事系统能够适应不断变化的战场环境，提高对抗效能和反应速度。这些技术的应用，为智能化指挥控制、训练模拟和自主集群无人化对抗等方面提供了关键支持，对提升军事实力和应对复杂战场挑战有着重要意义。

然而，深度学习与强化学习等数据驱动算法由于其典型的“黑盒”特性，训练出的模型可解释性差。专家系统、决策树等知识驱动的方法能够充分利用领域先验知识，在可解释性上有着天然的优势。因此，为了解决这一问题，大量学者着眼于将知识驱动和数据驱动两大类算法相结合，提出了大量融合方法，如神经网络树^[4]、遗传模糊树^[5]、分层强化学习^[6]等。

目前，关于传统机器学习的可解释性研究仍然是一个重要的领域。这方面的研究主要有两个方向：一是直接构建易于解释的模型，使得模型本身具有可解释性；二是对数据驱动的模型采用可解释性方法进行解释。此外，知识与数据的迭代进化也引起了广泛关注。用知识引导数据模型的生成，并从数据模型中归纳出新的知识，实现知识和数据的交替迭代，这是实现智能系统自主进化的重要途径^[7]。这种迭代过程不仅可以帮助系统自主学习和提高性能，还能构建出超越人类知识范围但又具备可理解性的人工智能系统。

在此背景下，本文以规则演化理论为基础，结合军事博弈现实需求，采用知识与数据相结合的训练方法训练智能体决策策略。研究博弈对抗场景中的策略学习问题，旨在提高模型的可解释性和有效性，同时增强智能体的效率和灵活性，为军事指挥控制决策

提供更加精准、全面和适应性强的指导方案，促进军队向现代化和智能化转型的目标迈进。

1.2 国内外研究现状

1.2.1 多智能体博弈对抗策略研究现状

多智能体系统的研究和应用是人工智能领域的热点之一。这些系统是由一系列同构或异构的智能体构成，智能体之间相互作用，形成竞争或合作关系。这种互动能够促进智能体之间的学习和进化，使得整个系统能够处理更加复杂和多样化的任务和挑战。从 1950 年开始，智能体博弈对抗日益成为国内外人工智能研究中备受关注的领域之一。2016 年，DeepMind 团队成功开发出 AlphaGo^[8] 围棋程序，通过深度强化学习（Deep Reinforcement Learning, DRL）算法，击败了围棋世界冠军李世石，这一成就在全球范围内引起了轰动，激发了人们对智能体博弈对抗领域的兴趣和研究热情。受 AlphaGo 的启发，各个领域开始投入到深度学习算法的研究中，尤其是复杂多变的智能空战领域。在此之前，传统的对抗推演主要依赖于固定的思维模式，例如事件驱动和规则驱动等方式，智能体主要基于规则和分层状态机等策略进行决策，并以事件驱动机制进行推演^[9]。然而，随着机器学习技术的飞速发展，国内外在各种棋类和策略类游戏领域中取得了新的研究成果，智能兵棋和智能对抗推演也实现了新的突破和发展。鉴于多智能体博弈对抗领域丰富的研究工作，本节将梳理多智能体博弈对抗策略的研究现状。

1.2.1.1 基于专家系统的方法

专家系统是一种基于人工智能的计算机系统，其核心思想是模仿人类专家的知识储备和推理过程，解决特定领域内的复杂问题，并得出与专家相同的结论。简单来说，专家系统可以视作“知识库”和“推理机”的组合^[10]，如图 1-1 所示。




图 1-1 专家系统示意图

专家系统的发展过程经历了 5 个阶段，如图 1-2 所示^[10]。




图 1-2 专家系统发展过程

基于规则的方式包括专家提出规则和算法生成规则两种。前者依靠专家经验讨论得到，后者是依据一套算法体系，自动从数据中获取规则。基于框架的专家系统可以看作是基于规则的延申，它将知识表示为一种框架结构，包含事实、规则以及推理过程。基于案例的专家系统通过利用过去的案例来解决当前的问题。然而，传统的专家系统缺乏对知识的重用性和共享性，为了克服这些问题，研究者提出了基于模型的专家系统，主要包括因果时间模型和神经网络模型。因果时间模型与人类的认知习惯相符，对于理解物理系统非常关键。神经网络模型与传统的产生式专家系统有着本质区别，它将知识从显性转变为隐性，在隐藏层的参数竞争中自动获取知识。这种模型具有较强的学习和适应能力，并且在处理复杂问题时表现出优势。为了充分发挥两种方式的优点，将神经网络与专家系统相结合，可以提高专家系统的性能，也能为实际问题提供科学、有效、全面的方案。随着互联网的发展，网络也成为用户间交流和信息获取的交互接口，用户通过浏览器访问专家系统服务器，与专家系统交互获取相关信息和解决方案，服务器通过后台推理机以及数据库、知识库来推导结论，并由浏览器传递给客户。这种基于网络的专家系统极大地扩展了专家系统的应用范围，为用户提供更加智能和便捷的服务。

在智能空战领域中，基于专家系统的方法通过整合领域知识，构建专家知识库，指导智能体进行决策。自 1969 年起，Burgin 和 Owens 在 NASA 兰利研究中心的资助下，开发了自适应机动逻辑（Adaptive Maneuvering Logic, AML）决策软件，用于微分机动模拟器（Differential Maneuvering Simulator, DMS）^[11]。AML 系统不仅能够模拟敌方飞机与使用模拟器的飞行员进行实时对抗，还能够实现对飞机参数以及性能的研究，为空战决策提供了支持，也为航空航天领域的决策技术注入了新的思路和方法。在此基础上，为了应对高速变化的战场环境，NASA 兰利研究中心继而研发出基于知识的战术决策生成器 PALADIN 系统^[12]。该系统的知识库不依赖于飞行员经验，而是根据飞机参数和仿真对抗数据构建而成，为新型飞机提供丰富的决策支持，实现了决策规则的自动生成，这种方法不仅弥补了实战经验缺乏的问题，还提高了决策的效率和准确性。

1.2.1.2 基于群体智能的方法

群体智能方法是一种模拟自然界中群体行为的计算方法，灵感来源于对昆虫群体如蚂蚁、蜜蜂等的研究。这些研究表明，即使个体具有简单的行为规则，但整个群体能够通过协作和信息交换，展现出高效的群体智能。这种方法被引入到计算机科学领域，在优化问题、模式识别、智能体决策等方面得到广泛应用。常用的群体智能方法包括蚁群算法(ACO)^[13]、粒子群优化算法(PSO)^[14]、人工蜂群算法(ABC)^[15]、萤火虫算法(GSO)^[16]等。群体智能优化算法总结如图 1-3 所示。在优化问题中，例如蚁群算法模拟蚂蚁寻找

食物的行为,通过信息素沉积和挥发来搜索最优解。在模式识别中,鱼群算法模仿鱼群的聚集和散开行为,用于图像分割和特征选择等任务。这些方法模拟了自然界中群体协作的行为,能够有效地解决复杂的优化和搜索问题,为人工智能领域带来了新的思路。




图 1-3 群体智能优化总结

苏菲等人^[17]利用蚁群算法,在传统的无人机协同多任务分配模型基础上,考虑了多种复杂约束条件,如无人机任务能力差异和动态任务时间限制等,对其进行扩展,有效地解决了多个无人机任务的分配和协同问题。Jevtic 等人^[18]提出了分布式蜜蜂算法(DBA)用于机器人群中的任务分配问题,该方法具有高可扩展性,适用于机器人数量和数量不同的情况,同时该算法还具有对目标质量不均匀分布的适应性,可以有效地解决这一问题。程子龙等人^[19]提出了基于改进 PSO 算法的导弹防御多智能体决策支持系统,通过变邻域负选择粒子群优化算法进行决策,并与多种改进粒子群算法对比,构建的多智能体决策支持系统可以自动生成拦截计划,并支持导弹防御过程的三维动态显示。梁鹏等人^[20]提出了一种基于神经网络和粒子群优化的多智能体机器人系统决策方法,通过粒子群算法训练神经网络,实现机器人智能体动态自适应地学习。

1.2.1.3 基于遗传及进化算法的方法

遗传算法是一种基于生物进化规律的随机化搜索算法,通过模拟“染色体遗传”和“适者生存”原则演化解空间,它直接操作结构对象,利用概率化寻优方法自动探索搜索空间,生成一群候选解并寻找最优解。在解决复杂优化问题方面,遗传算法表现出强大的能力,它能够实现并行训练,具有鲁棒性强和搜索范围广等特点。遗传算法作为一种通用的优化方法,具有较强的搜索能力和适应性,为解决复杂问题提供了有效的解决方案,因此,遗传算法大量被用于深度神经网络模型参数的学习^[21],模型架构的设计^[22]等。

Salimans 等人^[23]提出进化策略由于其高度可并行性,训练效率大大提高,使用虚拟批量标准化和神经网络策略的重参数化极大地提高了进化策略的可靠性,另外,进化策略比一些强化学习算法表现出更好的探索行为,因此可以作为基于马尔可夫决策过程(Markov Decision Process, MDP)的强化学习算法的一种代替。Khadk 等人^[24]提出了进化强化学习算法(Evolutionary Reinforcement Learning, ERL),该算法结合了进化策略的多样性探索和深度强化学习的基于梯度的方法,种群中的个体定期向强化学习模块传递互动轨迹,强化学习模块训练后向进化模块传递梯度信息,实验表明 ERL 算法表现

优于先进的强化学习算法，包括 PPO（Proximal Policy Optimization）和 DDPG（Deep Deterministic Policy Gradient）算法。

Madushani 等人^[25]提出了一种适用于多智能体系统的扩展遗传算法，将进化博弈论的随机策略和邻里策略应用到基于遗传算法的多智能体系统中，在一个多机器人导航应用实例中该方法的收敛速度更快。Wang 等人^[26]研究了混合策略下基于动态进化博弈论和分布式决策的编队控制与碰撞问题，智能体通过遗传算法选择特定策略，目标是以更少的时间和更小的损失形成队形，研究结果为基于进化博弈的编队控制和碰撞提供了一些创新思路。

Zhou 等人^[27]将自动深度神经网络的构建表述为一个带有约束的多层次多目标优化问题，从模型参数优化、模型架构优化以及模型学习器优化三个方面总结了基于进化算法解决该方法的方法，其在无人机、机器人、生物医学工程等领域有着广泛的应用。Shao 等人^[28]提出了一种基于分解和优势的端到端多目标神经进化算法，通过进化操作和奖励信号来进化神经网络，在旅行商等问题上具有竞争力和鲁棒性。Lin 等人^[29]提出了多智能体强化学习模型和基于进化策略的混合交通控制方法，将图注意力网络引入深度 Q 网络，用于车辆决策，采用演化策略来提供实时速度限制，实验结果表明，该方法在吞吐量、平均速度和安全性等指标上有较好的表现。

在联合对抗背景下，针对联合火力打击任务规划问题，刘昊等人^[30]提出了一种智能对抗进化算法，以遗传算法为基础，在敌我双种群的竞争机制下进行对抗进化，促使个体在动态变化的战场环境中适应和优化任务规划，实验结果显示，经多代进化后的最优个体相较于标准优化结果，具有更强的战场动态适应性以及更高的联合火力打击胜率，能够有效地解决联合火力打击任务规划的评估优化问题。邢岩等人^[31]提出了基于智能进化算法的火力打击战法策略优化方法，利用智能体和种群的双层构造和对抗推演中的反馈评分实现智能体智力的提升，进而通过种群进化实现战法策略的优化。实验结果表明，该设计思想在整体效果上优于传统的遗传算法和对抗进化算法，同时具备可扩展性和广泛的应用性。

1.2.1.4 基于神经网络和强化学习的方法

DeepMind 团队自 2015 年提出深度 Q 网络以来，认为深度强化学习能够实现人类水平的控制^[32]。为此，他们推出了 AlphaGo^[8]、AlphaGo Zero^[33]和 AlphaStar^[34]等基于深度学习和策略搜索的方法，这些系统不仅在棋类、策略游戏中取得了超越人类的成就，还在智能体深度强化学习领域掀起了一股新的热潮。其中，AlphaGo Zero 甚至无需人类经验就能够在短时间内战胜 AlphaGo，而 AlphaStar 在《星际争霸 II》游戏中的表现更是超过了 99.8% 的人类水平。基于深度学习和策略搜索的机器人技术已经在复杂的策略游戏中取得了重大突破，达到了可以与顶尖人类玩家媲美的水平。

在单智能体强化学习中，研究重点在于如何找到最佳策略以最大化任务奖励。然而，在多智能体环境中，由于系统的不稳定性，多智能体强化学习变得更加复杂。相较于单智能体情况，多智能体强化学习的目标是寻找能够实现纳什均衡、收敛到最优解或获得

最大奖励的策略，以完成多智能体相关任务。这种方法不仅需要考虑个体智能体的学习，还要处理智能体之间的相互作用与协调，因此对于解决多智能体协同决策问题具有重要意义。

针对深度强化学习在多智能体系统的应用，有大量研究创新。一类方法是基于 Actor-Critic 框架的，如 MADDPG^[35] (Multi-Agent Deep Deterministic Policy Gradient) 算法，它利用集中式训练和分散式执行的方式，使每个智能体在训练阶段接收全局信息即所有智能体的观察和动作，而在执行阶段仅接收局部信息即当前智能体的观察，以解决多智能体系统中的协作问题。COMA^[36] (Counterfactual Multi-Agent Policy Gradients) 算法引入了反事实基准，解决了多智能体信用分配的问题。另外，MAAC^[37] (Multi-Actor-Attention-Critic) 算法通过每个智能体拥有独立的 Actor 和 Critic 网络，并引入共享参数的注意力机制、Soft Actor-Critic (SAC) 和反事实基线等方法，更好地关注重要智能体的信息。

还有一类基于值函数分解的方法，其中 VDN^[38] (Value-Decomposition Networks) 在 DRQN^[39] (Deep Recurrent Q-Network) 的基础上，提出了一种值分解网络架构，这种方法能够在只有全局奖励的情况下，有效地学习不同智能体的 Q 值，从而解决了部分可观测导致的伪收益和懒惰智能体问题。在 VDN 算法的基础上，QMIX^[40] (Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning) 采用混合网络将单智能体价值函数映射为非线性的全局价值函数，并施加一种单调性约束。QTRAN^[41] 则提出了一种更加泛化的值分解方法，通过惩罚项对约束进行限制，从而在处理不同环境下的智能体时更具灵活性和泛化能力。Qatten^[42] (Q-value Attention Network) 研究了联合行为价值函数在最值点附近的分解性质，并引入了多头注意力机制以逼近理论分析结果。最后，QPLEX^[43] (DUPLEX Dueling Multi-Agent Q-learning) 提出了基于优势函数的个体-全体最大原则 (Individual-Global-Max, IGM)，并将动作值函数一致性约束转化为优势函数的一致性约束。

在此基础上利用深度强化学习算法训练智能体在军事领域中也大量研究。Kong 等人^[44]对 DDPG 算法进行了改进，以提高智能体的决策鲁棒性和算法收敛速度。他们引入正则化器来增强策略网络的鲁棒性，以应对飞机传感器误差对决策带来的影响。另外，他们利用最大熵逆强化学习算法对奖励函数进行规划，进一步优化算法的收敛效果。Bai 等人^[45]采用 TD3 (Twin Delayed Deep Deterministic policy gradient) 算法，训练了无人机自主机动模型，使得无人机能够根据环境中的位置、速度以及方位角等态势信息，做出智能化的自主机动决策。

1.2.2 规则学习研究现状

当前规则学习算法可以分为两类：第一类算法是先学习个体决策规则，然后再对这些规则进行汇总生成规则集，通常采用贪心策略，旨在尽可能多地发现规则，以提高对未知情况的适应能力^[46]。另一类算法是从一组决策树中提取规则集合，并且通过 L1 正则化优化来构建规则集的加权组合^[47]。

与一些常见的机器学习算法相比,规则学习可解释性强,但在准确性方面表现较差。这是因为规则学习难以处理连续变量,离散化过程中会丢失大量信息,同时,在规则学习过程中容易出现过拟合问题^[48]。

为了提高规则学习的准确性,有些研究者结合机器学习和基于规则的智能系统的优点,以取长补短并实现更佳的效果^[49]。其中一种方式是基于规则的机器学习系统(Rule Based Machine Learning, RBML),它能够识别并利用一系列关系规则,这些规则可以由系统自身的学习算法和知识库完成,无需进行人工编码或手动定义 "IF/THEN" 语句。通过这种方式, RBML 系统不仅提高了效率,还增强了自适应性和灵活性,能够更好地适应各种应用场景的需求。

1.2.2.1 学习分类器

学习分类器系统(Learning Classifier System, LCS)是一种基于规则的机器学习方法,最早由 Holland 提出,旨在解决复杂自适应系统中基于规则的代理表示问题^[50]。Holland 认为当复杂系统具备从经验中学习的能力时,便具备了“自适应性”。复杂系统可被视作一组相互作用的代理,其中每个代理的行为都可以用一组简单的规则表示,通常采用“IF 条件 THEN 动作”的形式。面对复杂系统时,寻找一个最适合的模型不如进化出一群规则来共同为该系统建模。LCS 中涉及到不同研究方法的合并,其综合了人工智能、进化算法、强化学习等多种思想与方法,如图 1-4 所示。




图 1-4 学习分类器系统涉及方法

Holland 最早的实现被称为认知系统-1 (Cognitive System One, CS-1), 是第一个将信用分配方案与遗传算法合并在一起的系统, 其中遗传操作在单个规则级别上进行, 解决方案由整个规则种群表示。这种方法与其他早期 LCS 算法相比, 过于固定且对系统操作缺乏理解。Smith 等人^[51]提出了另一种 LCS 算法 LS-1 (Learning System One), 其特点是包含可变长度的规则集, 且遗传算法通常在整个规则集级别上操作, 另外, 他的奖

励分配是给整个规则集，而不是单一规则。这两种方法中 LS-1 的关注度更多，因为它可以应用于更广泛的问题领域，解决更大、更复杂的问题。Valenzuela 等人^[52]提出了模糊 LCS，将模糊逻辑和基于规则的 LCS 结合起来，是第一个探索超越简单三元系统规则表示的系统之一。Meyer 等人^[53]对于分类器的潜在学习问题展开研究，它能够利用当前信息和过去经验，通过对模型内部理解，基于未来状态的预测来执行动作。这项工作引导产生了学习分类器的一个研究分支：预测性分类器系统（Anticipatory Classifier Systems, ACS）^[54]。1994 年，Wilson 为简化 LCS 系统，并提高其可解释性和性能，提出了“零级”分类系统（Zero-level Classifier System, ZCS）^[55]。与标准 LCS 框架不同的是，ZCS 忽略了很多附加的算法组件，使用一种新的分配策略。在此基础上，Wilson 又提出一个扩展分类器系统（eXtended Classifier System, XCS），它保留了大部分 ZCS 架构，将适应度设置为精度，与 ZCS 中基于强度的适应度截然不同，这种设计使得解更加全面和准确，而不是简单关注环境中更高收益的值^[56]。在 XCS 后，Stolzmann 引入了 ACS，它能够基于给定环境中所有可能的情况下预测一个行为的感知后果，最明显的算法差异是以条件效果的方式表示规则，而不是以经典的条件动作形式表示，该架构适用于多步骤问题^[57]。

近年来，学习分类器系统在各个领域中有大量应用。Kim 等人^[58]将卷积神经网络和学习分类器结合起来，提出基于卷积神经网络的学习分类器系统，通过使用卷积神经网络作为分类器的动作，提高了分类精度。Richard 等人^[59]基于 XCSF（eXtended Classifier System with Features）框架进行扩展执行深度学习，实现自适应计算。种群内的个体分类器由两个神经网络组成，允许在每个实例的基础上对相关的深度神经网络进行条件计算，另外，在复制过程中采用自适应突变。Irfan 等人^[60]提出一种卷积自编码器增强学习分类器系统，实现对大尺寸水下图像分类，并获得相关规则，实验表明其具有良好的分类精度，优于已知的卷积神经网络，且学习分类器生成的规则具有良好的泛化性与可解释性。Uwano 等人^[61]针对复杂的多步骤问题引入了基于 XCS 框架的分层学习分类器系统的方法，将连续的别名状态连接起来，形成离散的唯一状态，实验表明此方法克服了现有系统的问题，性能优于基线。

1.2.2.2 决策树及优化

决策树（Decision Tree, DT）是典型的分类器，它使用类似流程图的树结构来描述。相较于其他学习算法，决策树归纳算法具有几个优点，如对噪声的鲁棒性、低计算成本以及处理冗余属性的能力。此外，诱导出的模型通常具有良好的泛化能力。

大多数决策树归纳算法采用贪婪的自上而下递归分区策略来构建。它们使用不同度量标准，如信息增益、增益比、基尼指数和基于距离的度量等，来选择与内部节点关联的输入属性。贪婪搜索的一个主要缺点是可能会导致次优解决方案。此外，递归分区数据集可能会导致在树的最深节点中进行属性选择的数据集非常小，使得数据过拟合，当特征之间存在相关性时，决策树可能无法准确地捕捉和分离这些相关性。

随机森林^[62]通过集成多个决策树来克服决策树的一些缺点，基于随机抽样的方式生成多个决策树，并通过投票或平均方式集成这些决策树的预测结果，从而降低模型的过拟合风险。此外，随机森林在处理高维数据和大规模数据时表现较好，并且能够处理具有复杂关系的特征，提供特征重要性评估，帮助研究者理解和选择最相关的特征。由于每棵决策树可以独立构建，随机森林可以有效地并行化处理，提高训练效率。

针对遗传算法，目前已有相关文献将其应用到决策树中，一种方式是直接对决策树进行进化，Aitkenhead 采用树编码的方式，对决策树进行协同进化^[63]；另一种方式是将进化算法用于改进决策树分类器的特定组件：如树的修剪^[64]、计算分类成本^[65]、控制树的参数^[66]等。随着机器学习和自动决策系统的日益普及，人们对可解释的机器学习越来越感兴趣，即构建在某种意义上可以被人类理解的模型^[67]。决策树作为典型的规则学习算法，因为其具有良好的实用性、可解释性和鲁棒性等优势，许多研究人员已将注意力转向该领域。Custode 等人^[68]结合了进化算法和 Q-learning 的优点，提出了一种决策树进化学习方法，通过两级优化方案指导决策树学习，并获得很高的可解释性。Nicholas 等人^[69]将遗传模糊树引入到无人机对抗控制问题中，通过遗传模糊树训练一批模糊推理系统，具有非常高的性能和效率，能够完成未经训练的新任务。Hinton 等人^[70]提出了一种软决策树，通过层级决策模型表示深度神经网络，平衡了泛化能力和可解释性之间的关系。

1.3 论文研究内容

本论文旨在研究基于规则演化的多智能体博弈对抗策略。在多智能体博弈对抗领域中，特别是涉及联合对抗的复杂场景，由于参与对抗的单元众多，对抗背景错综复杂，传统的多智能体策略探索方法难以取得理想效果。针对这一问题，目前主流趋势是采用深度学习、强化学习等先进算法，但是当前研究仍然存在以下问题：

(1) 模型解释性有待提高。由于神经网络的复杂性和不透明性，基于深度学习和强化学习的智能体决策模型的训练过程和策略形成机制难以被透彻理解。智能体所获取的决策经验难以用系统性和可解释的方法进行提取和阐释。

(2) 专家数据难以收集。当前关于智能体博弈对抗的专家指导大多依赖于先验知识，针对军事联合对抗背景下的专家数据难以收集，应用受限。

(3) 知识与数据迭代进化有待提高。以知识引导数据模型的生成是智能系统演进的关键步骤，这种方法通过将先验知识融入到数据模型的构建中指导模型生成，并从中提取出潜在的规律。在此基础上，通过对数据模型的归纳分析，产生新的知识规则，从而丰富系统知识库。这种知识与数据交替迭代的过程也成为重要的研究方向。

机器学习中的可解释性一般定义为能够以易于理解的方式向人们解释或者呈现其决策过程的能力，使得用户不仅能够直观地了解模型结构，还能理解输入变量如何在数学上映射到输出结果。可解释性一般可分为内置可解释性和事后可解释性两类。内置可

解释性是指模型本身具有自我解释的能力。事后可解释性是指在建立模型后，通过解释性方法揭示模型的决策依据。

为了有效解决上述问题，本论文将进行以下 3 个方面的研究：

第一部分是提高决策模型的内部可解释性，针对空战环境设计一种基于学习分类器系统的智能体决策模型。首先，通过专家知识设计规则表示方式，构建分类器库。采用强化学习的思想不断与环境进行交互获取奖励值，设计规则评估机制，根据奖励值更新分类器库中的适应度，进一步训练学习分类器系统。其次，设计基于遗传算法的规则发现机制，产生更多的分类器后代，借鉴生物界的“优胜劣汰”法则，更新分类器库。最后，在给定军事对抗环境中，验证算法在复杂博弈对抗场景下的有效性。

第二部分是在第一部分基础上，进一步提高模型的对抗能力。在防空对抗军事背景下，考虑到现有强化学习模型可解释性不足的问题，结合可验证性策略提取算法，实现对已训练强化学习模型的策略提取，基于规则的方式将强化学习模型用一个决策树模型替代，验证决策树模型的有效性。为了进一步解释模型，对决策树进行决策规则提取，分析形成策略规则，扩充策略规则库，构建博弈对抗策略决策树。

第三部分是在第二部分工作基础上，对提取出的决策树加入遗传算法，产生更多的决策规则，实现知识与数据迭代进化。挖掘新生成的决策树中隐藏的策略规则，形成博弈对抗策略决策树，与第二部分的策略规则进行对比。

1.4 论文组织结构

如图 1-5 所示，本文共分为六章，各章的主要内容具体如下。

第一章：介绍本文的研究背景和研究意义，从多智能体博弈对抗策略学习和规则学习两个角度介绍本论文相关的国内外研究现状和现存问题。

第二章：主要介绍本文所需的相关理论和基础知识。

第三章：针对研究内容第一部分，本章提出了一种基于学习分类器系统的智能体决策模型。首先明确了模型设计目标和实验平台，然后对本章的设计工作进行了详细的介绍，包括模型结构、决策规则表示等，最后基于空战场景验证了模型的有效性。

第四章：针对研究内容第二部分，本章在训练好的强化学习模型上，基于策略提取算法实现强化学习模型的近似和解释，提取出的规则用决策树表示。首先，对强化学习模型进行介绍，并在此基础上详细阐述了策略提取算法和策略规则挖掘的原理和实现过程，最后对提取出的决策树的有效性和解释性进行了验证分析。

第五章：针对研究内容第三部分，提出了一种基于遗传算法的决策树演化方法，利用遗传算法探索解空间，提高决策多样性，并在典型博弈对抗场景下进行了实验验证。同时，通过对决策树的规则提取与分析，获取新增的策略规则表，构建博弈对抗决策树，进一步扩充了策略规则库。

第六章：对全文工作和主要成果进行总结，并对未来工作的重点进行展望。




图 1-5 论文研究内容与组织架构

第二章 预备知识

2.1 规则学习相关理论

规则学习是从训练的数据集中，提取出一组用于对新数据进行判别的规则。机器学习中的规则通常是指含义明确，能够揭示出数据集中隐藏的规律或者相关领域概念，能够用“IF...THEN...”的形式表示出来的逻辑规则，由一个或多个条件和一个预测组成。规则学习与神经网络等“黑盒模型”相比，具有良好的解释性，能够帮助用户更直观地了解判断过程。基于规则的机器学习方法主要包括学习分类器系统^[50]，关联规则学习^[72]，决策树^[73]，以及任何其他依赖于规则的方法，每种方法都涵盖上下文知识。本节主要介绍学习分类器相关知识。

2.1.1 学习分类器

学习分类器系统的核心就是一组规则，其目标是创建一个分类器集合，从而模拟智能决策系统。在定义分类系统时，状态值一般通过一组检测器传递给系统，经过相关处理作为标准化消息，再经过系统的效应器执行动作，在这个过程中，系统与环境处于不停交互状态。最重要的是，环境必须为系统提供一些性能度量来指导分类器系统学习。

分类器系统主要解决机器学习中的三个基本问题：1、并行性与协调性。系统对于处理诸如“路边有一个带着红色帽子的女人，正在吃汉堡”这样整体的规则很困难，但是如果将其分解为“构建块”的形式，并激活“路边”，“女人”，“红色帽子”等进行处理会相对轻松。分类器系统通过一个个“构建块”规则的组合，用消息中“寻址”的方式，处理复杂新奇的情况，它可以为同时处于激活状态的大量规则提供交互和协调。2、信用分配机制。信用分配机制主要用于确定分类器系统中哪些规则对其成功更有作用。如果系统没有持续受到监督，就需要信用分配机制指导系统学习。3、规则发现机制。规则发现机制一般来说，信用度低的规则应该被替换，但是随机生成的新规则只适用于很少的问题，关键是如何利用过去的经验对新的情况做出合理的假设。

尽管有许多不同的 LCS 算法实现，但在 Holmes 等人的研究中，总结了四个实际通用的组件^[74]，如图 2-1 所示，其中包括：

- (1) 初始种群：代表系统当前分类器集合。
- (2) 性能组件：调整环境和分类器种群之间相互作用。
- (3) 信用分配组件：将从环境中收到的奖励分配给分类器。
- (4) 发现组件：该组件使用不同的算子来产生更好的规则并改进现有规则。

上述四个组件代表了学习分类器的算法框架，还有两个主要机制负责驱动系统：遗传算法和适合于给定问题的学习机制。这两种机制都依赖于环境，可以说，环境是 LCS 算法学习的数据来源，从环境中传递的信息与具体研究问题有关，通过与环境互动，LCS 以数字奖励的形式接收反馈，从而推动学习过程。




图 2-1 学习分类器组件

LCS 可以看作是一个在任意环境中工作的学习代理。为了与环境相互作用，它有一个获取环境信息的输入接口和一个执行动作的输出接口。输入接口的每个检测器包含关于环境状态的一个属性值。因此，LCS 对环境状态的获取都用称为消息的位串表示。消息是环境状态的内部表示，每个组件包含一个检测器的信息。形式上，分类器是一个条件/动作规则，一般用“IF 条件 THEN 动作”的形式表示。如果分类器的条件部分与当前消息匹配，那么分类器就可以激活。

LCS 的执行通过下述步骤进行迭代：

1. 获得消息 M。
2. 将消息 M 与当前分类器列表中所有分类器的条件部分进行比较。匹配成功的分类器形成匹配集。
3. 通过选择算子从匹配集中选择一个分类器。
4. 所选的分类器变为激活状态。LCS 执行相应的动作。
5. 动作执行后获得环境给出的奖励，对激活的对应分类器适应度值进行更新。
6. 通过规则发现机制产生新的分类器，同时取代种群中低适应度分类器。

分类器的表示一般使用字符串的形式，将每个位置视为表示谓词的值（1 表示真，0 表示假，或其他复杂的表示），遗传算法将这些字符串配对产生新的规则。

2.2 决策树相关知识

决策树是一种常见的机器学习模型，主要用于分类和回归问题，是一种有监督学习。它能够从一组有特征和标签的数据集中总结出相应的决策规则，并用树形决策图的形式展示出来。如图 2-2 所示为决策树示意图，其中内部节点表示对一个属性值的判断条件，分支代表不同的判断结果，叶节点表示决策结果，从根节点到叶节点为一个决策序列。与机器学习其他算法相比，决策树算法更容易理解，可解释性强，适用于不同类别的数据集，在各个领域中都有不错的表现。但是，决策树算法不易处理连续型数据，在处理

连续型数据时必须将其转化为离散型才能进行操作。对于空缺数据的处理也存在难度，可能会产生错误。决策树在训练生成过程中，容易陷入局部最优，原因在于传统决策树算法在特征划分时通常考虑当前节点的最优，而没有考虑全局下如何对特征空间进行划分。另外，决策树训练可能会出现过拟合问题，要搭配剪枝处理进行优化。本节主要从决策树生成、划分标准以及相关算法进行介绍。




图 2-2 决策树示意图

2.2.1 决策树生成

在决策树生成过程中，一般需要两部分数据集：训练数据和测试数据。

决策树的归纳方法通常采用自顶向下的策略，通过递归地划分数据集来构建决策树。该方法遵循“分而治之”的思想，将数据集不断细分为更小的子集。Rokach 等人^[75]提出的自顶向下的决策树归纳流程如算法 2.1 所示。递归的终止条件有三种情况：

其一，假设当前节点所包含的数据归属于同一类别，已经达到了纯度，则不必再做进一步的区分，该节点被标记为叶子节点。

其二，若当前节点属性集为空或所有数据在属性上取值相同，无法再分，则该节点成为叶子节点，以含样本最多类别为其类别。

其三，如果当前节点所包含的样本集为空，即没有数据可供划分，同样将该节点标记为叶子节点，其类别设为其父节点包含样本最多的类别。

搜索策略的不同在于选择划分特征 A 的方式不同。例如，前向搜索策略会以某个特征 A_i 作为基础，通过向前探索一定步数进行划分。在每一步划分后，生成子树并评估该特征的优劣。而集束搜索策略则会同时选择一组候选特征，以并行方式构建多个树结构，最后从中选择表现最佳的树结构作为最终的决策树，或将部分甚至全部树结构组合成决策森林。对于连续特征，通常会选择一个特定的取值作为分界点，将样本数据划分为两个互不相交的子集。这种划分方式可以在处理连续特征时保持决策树的一致性。

算法 2.1: 自顶向下的决策树归纳算法

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;

特性集 $A = \{A_1, A_2, \dots, A_n\}$

过程: 函数 $TreeGenerate(D, A)$

输出: 以 node 为根节点的决策树

- 1: 生成节点 node;
 - 2: if D 中的样本属于同一类别 M then
 - 3: 将 node 标记为 M 类叶子结点; return
 - 4: end if
 - 5: if $A = \emptyset$ or D 中样本点在 A 上取值相同 then
 - 6: 将 node 标记为叶子节点, 其类别标记为 D 中样本数最多的类; return
 - 7: end if
 - 8: 从 A 中选择最优划分特征 A_i ;
 - 9: for A_i 的每一个值 A_i^v do
 - 10: 为 node 生成分支; D_v 表示在 A_i 上取值为 A_i^v 的样本子集;
 - 11: if 为空 then
 - 12: 将分支节点标记为叶节点, 其类别标记为 D 中样本数最多的类; return
 - 13: else
 - 14: 以 $TreeGenerate(D_v, A_i)$ 为分支结点
 - 15: end if
 - 16: end for
-

2.2.2 划分标准及算法

在决策树生成过程中, 究竟哪个特征更好, 如何划分能使模型的准确度更高, 这就需要确定一个划分标准判断内部节点的优劣。首先了解一下信息熵(entropy), 熵定义为信息的期望值, 通过公式 $Ent = -\sum_{i=1}^n p(x_i) \log_2 p(x_i)$ 得到, 其中 n 为类别数目。熵表示随机变量的不确定性, 熵越大, 随机变量的不确定性就越大。以下介绍常见的三种划分标准: 信息增益(Information Gain)、增益率(Gain Ratio) 和基尼系数(Gini Index)。

(1) 信息增益

信息增益表示, 在一定条件下, 信息不确定性的减少程度, 信息增益是相对于特征来说的。对于有 n 个不同取值的属性 a , 第 i 个取值为 a_i 。根据 a 的不同取值将数据集 D 划分为 n 个互不相交的子集 D_i 。根据信息熵的计算公式可以得到每个子集的信息熵 $Ent(D_i)$, 由于每个子集样本量不同, 且通常认为样本数越大的集合影响越大, 因此给每个子集增加权重 $|D_i|/|D|$ 。属性 a 对数据集 D 的信息增益为:

$$Gain(D, a) = Ent(D) - \sum_{i=1}^n \frac{|D_i|}{|D|} Ent(D_i) \quad (2.1)$$

信息增益越大，表示用该属性划分数据集 D 的效果越好。

ID3 算法是一种经典的决策树学习算法，它将数据集划分为训练样本集和测试样本集，并使用信息增益作为划分标准。在递归过程中，每次都会选择具有最大信息增益的属性作为当前节点的分裂属性，然后继续向下构建决策树，直到满足停止条件。这一过程不断重复，直到所有样本都被正确分类或者达到了预定的停止条件。ID3 算法的核心思想是通过不断地选择具有最大信息增益的属性来构建一个能够最好地分类样本的决策树模型，从而实现了对未知数据的准确预测。由于没有剪枝策略，ID3 算法容易出现过拟合的情况，且由于信息熵的设定，取值数越多的特征的信息熵会越大，则节点划分会偏向于取值数目较多的属性，导致每个分支样本数过少，如果每个分支只包含一个样本，则每个子集的信息熵都为 0，信息增益最大，但这种分类毫无意义。

(2) 增益率

针对上述问题，C4.5 算法提出了信息增益率，定义如下：

$$Gain_ratio = \frac{Gain(D, a)}{IV(a)} \quad (2.2)$$

其中

$$IV(a) = - \sum_{i=1}^n \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|} \quad (2.3)$$

定义为属性 a 的固有价值(intrinsic value)。当属性 a 的取值越多，则 $IV(a)$ 值越大。与信息增益相反，增益率会偏向于取值数目较少的属性，在实际应用中，会将信息增益和增益率搭配使用。

C4.5 算法使用信息增益率来进行属性划分，并在 ID3 算法的基础上改进了对连续型数据和空缺值的处理。相较于 ID3 算法，C4.5 首先会选出信息增益高于平均值的属性，再从中选择增益率较高的属性作为分裂点，从而克服了 ID3 算法偏向选择取值较多属性的问题。

(3) 基尼系数

基尼系数是另外一种用于衡量样本集合纯度的指标。基尼值用来表示在样本集合中随机抽取两个样本，其类别不一致的概率。因此，基尼值越小，样本集合的纯度就越高。给定有 n 个类别的样本集 D ，其中第 i 类的比例为 p_i ，记 i' 为集合中除了第 i 类以外的其他类别，那么基尼值可通过下式计算

$$Gini(D) = - \sum_{i=1}^n \sum_{i \neq i'} p_i p_{i'} = 1 - \sum_{i=1}^n p_i^2 \quad (2.4)$$

与信息增益类似，选择包含 n 个不同取值的属性 a 将样本集 D 划分为不同的子集 D_i ，此次划分的基尼系数定义为

$$Gini_index(D, a) = \sum_{i=1}^n \frac{|D_i|}{|D|} Gini(D_i) \quad (2.5)$$

分类回归树(Classification And Regression Tree, CART)算法是一种使用二分递归分割技术构建决策树的方法,适用于分类和回归问题,它通过将当前样本划分为两个子样本来构建决策树,即使特征有多个取值,也会将数据划分为两部分,确保每个非叶子节点都拥有两个分支,这种方法保证了生成的决策树均为结构简洁的二叉树,易于理解和解释。CART 算法的灵活性使其既可以用于分类问题,也可以用于回归问题,二者的区别在于任务目标不同。当 CART 训练分类树时,划分标准为基尼系数,当 CART 训练回归树时,划分标准为均方误差。CART 算法不仅可以处理离散特征还可以处理连续特征。CART 分类树算法步骤如算法 2.2 所示^[76]。

算法 2.2: CART 分类树

输入: 训练集 D , 特征集 $A = \{A_1, A_2, \dots, A_n\}$ 停止条件

输出: CART 决策树

- 1: 生成根节点 `node`;
 - 2: **for** 特征 A_i
 - 3: **for** 特征 A_i 可能的取值 a_j
 - 4: 将训练集 D 根据特征 A_i 是否等于 a_j 分割为 D_1 和 D_2 两部分
 - 5: 计算特征 $A = a_j$ 条件下的基尼系数 $Gini(D, A_i^{a_j})$
 - 5: **end for**
 - 6: **end for**
 - 7: 在所有特征 A_i 以及所有可能的取值 a_j , 选择基尼系数最小的特征以及取值作为最优特征 A_* 和最优切分点 a_* , 基尼系数为基尼系数 $Gini(D, A_*^{a_*})$
 - 8: 根据最优特征和最优切分点对现节点生成两个子节点, 将 D 划分到两个子节点
 - 9: **do**
 - 10: 对两个子节点递归调用 2-8
 - 11: **while** 满足停止条件
 - 12: 生成 CART 决策树
-

2.3 遗传算法相关知识

遗传算法是以自然选择和遗传理论为理论基础,结合自然界“物竞天择,适者生存”的原理演变过来的。本节主要介绍遗传算法的基本概念和设计的基本环节。

2.3.1 遗传算法基本概念

遗传算法的基本流程如图 2-3 所示,该算法在执行过程中,首先对对象编码,生成染色体,这些染色体组成了初始种群。接着,针对每个个体计算其适应度值,然后根据

适应度值的大小，选择一些较优秀的个体进行交叉和变异操作。经过多轮迭代，不断优化种群中的染色体，直到满足终止条件为止。这种遗传算法模拟了自然界的进化过程，通过选择、交叉和变异等操作扩充种群，逐步找到最优解或者接近最优解的解决方案。




图 2-3 遗传算法流程图

遗传算法中涉及到以下概念：

- (1) 染色体：指个体的一种表现形式，通常使用二进制编码表示，包含个体的遗传信息。
- (2) 种群：指多个个体组成的集合，其中每个个体都是染色体。
- (3) 种群规模：指该集合中包含的个体数量，规模大小直接影响算法的搜索空间和效率。
- (4) 基因：指个体的某一特征，是染色体中的元素。

(5) 基因位：指某个基因在染色体中的位置。

(6) 适应度函数：用来评估种群中每个个体在特定环境下的适应能力大小，帮助确定哪些个体更适合生存和繁殖，从而引导进化的方向。

这些基本概念相互作用，共同推动遗传算法的演化过程，使得算法能够不断优化个体，最终达到最优解或者接近最优解的目标。

2.3.2 遗传算法的五个基本环节

遗传算法主要包含：染色体编码、种群初始化、适应度函数的设计、遗传操作（选择、交叉、变异）以及参数的设定。

1、染色体编码

遗传算法在处理问题时需要对研究对象符号化，以便进行遗传操作。常用的遗传编码方式包括二进制编码、实数编码等。对于解 x ，二进制编码用 0 和 1 表示，而实数编码则以向量形式 $x = (x_1, x_2, \dots, x_n)$ 表示，其中 x_i 为实数。经过对二进制编码和实数编码的研究分析后发现，尽管二进制编码和实数编码有不同的理论基础，但对问题的优化结果影响不大。一个好的编码方案应考虑完备性、复杂性和可扩展性。完备性指确保所有可能的解都能够被编码和表示出来，并且每个基因编码都对应着一个唯一的个体；复杂性包括基因串结构复杂性、计算复杂性和解码复杂程度等；可扩展性指能否灵活地适应不同数量和结构的对象，而不需要增加额外的时间复杂度。综合考虑完备性、复杂性和可扩展性等因素，可以设计出更加有效和实用的遗传算法编码方案，从而提高算法在解决实际问题中的表现和效率。

除了上述提及的编码方法外，还存在其他编码方案，如符号编码、格雷码编码和多参数编码等。符号编码将每个参数表示为符号，而不是二进制或实数值。格雷码编码是一种特殊的二进制编码，相邻数值的二进制表示仅有一个位数不同，这样可以减少错误的产生。多参数编码适用于具有多个参数的问题，它允许将这些参数以不同的方式组合在一起进行编码。

最终选择哪种编码方案应基于具体问题的特点进行分析，考虑问题的性质、参数数量、搜索空间的复杂度以及算法的要求等因素，以找到最适合的方案。

2、种群初始化

初始种群是迭代的第一代，一般通过随机方式生成。

3、适应度函数

适应度函数在遗传算法中扮演着至关重要的角色，它评估了个体在解决问题时的优劣程度。通过适应度函数的设计，可以实现种群中个体的优胜劣汰，使更优秀的个体能够在下一代中被更好地保留和传递。在实际问题中，不同的问题可能需要不同的适应度函数设计，这取决于问题的性质、目标和约束条件。通常，适应度函数应该能够准确地反映个体的解决方案对问题的贡献程度，同时也需要具有较好的区分度，以便于在种群

中对个体进行选择 and 进化。因此，适应度函数的设计需要结合问题的具体情况，充分利用问题的信息和特性，以提高遗传算法的性能和效率。

4、遗传操作

遗传算法中的核心操作包括选择、交叉和变异。选择操作基于个体的适应度值，遵循"适者生存"原则，保留优秀个体，有助于保持种群的优良特性。交叉操作通过基因交换，结合两个个体的优点，产生新的个体，促进种群的进化和优化。变异操作旨在引入随机性，防止算法陷入局部最优解。这些操作相互配合，确保了遗传算法在解决复杂问题时的有效性和鲁棒性。接下来对这三个遗传操作算子进行详细介绍。

(1) 选择

选择操作是决定个体优胜劣汰的关键步骤，它基于个体的适应度值来选取适应度较高的染色体，从而构建下一代种群。常见的选择方法包括轮盘法、随机遍历抽样法、排序法和锦标赛选择法。锦标赛选择法是其中一种应用广泛的选择方法，通过逐轮比赛，选出适应度最高的个体。具体来说，每一轮比赛中随机选择一定数量的个体进行竞争，然后从中选出适应度最高的个体作为优胜者，将其复制到下一代种群中。这一过程重复进行，直到选出足够数量的子代。锦标赛选择法的优点在于其全局寻优能力较强，能够有效保留优秀个体并避免过早收敛。

在实践中，锦标赛选择法的关键在于选择合适的竞争个体数量 k 。如果 k 设置过小，可能导致早熟收敛，使得种群缺乏多样性，从而影响了算法的全局搜索能力。相反，如果 k 设置过大，则无法充分发挥锦标赛选择的优势，因为过多的竞争可能使得适应度较高的个体无法被选中。因此，合理设置 k 值非常重要，需要根据具体问题的特性和种群的大小来进行调整。

(2) 交叉

交叉操作也称为重组，指对于选择的个体进行两两配对，并根据配对结果随机选取交叉点进行交叉操作，以产生新的个体。该操作有助于保持种群中的多样性，从而促进后代种群的进化和优化。常用的交叉方法有一点交叉、两点交叉、均匀交叉等。如图 2-4 所示为单点交叉操作。




图 2-4 一点交叉示意图

(3) 变异

变异操作是基于概率的，在遗传算法中通常以较低的概率发生，以减少对个体表现的潜在损害。在某些情况下，随着世代的演变，突变概率逐渐增加，以确保种群的多样性，避免进化停滞。然而，如果突变率过高，遗传算法可能会失去效果，变得与随机搜

索相似。常见的变异算子包括位翻转突变、交换突变等，它们可以在个体基因中引入随机变化，有助于增加种群的多样性，从而促进进化过程。

5、参数设定

遗传算法的关键参数包括种群规模、交叉和变异概率以及终止条件。种群规模的设定应考虑搜索范围和计算效率的平衡，过小可能导致搜索空间受限，而过大则会增加计算成本。交叉和变异概率直接影响种群的多样性，通常由经验确定，也可采用自适应方法确定。设定终止条件是确保算法有效结束的关键，可以通过设定遗传代数或观察最优解的稳定性来决定，确保算法有效终止。这些参数直接影响遗传算法的搜索性能和效率，需要综合考虑问题特性和计算资源，合理设定以优化算法的执行效果。

2.4 本章小结

本章对研究工作中涉及的基础理论、知识以及技术进行介绍，主要包括学习分类器涉及到的规则学习相关理论，决策树生成、划分标准及常见算法等决策树相关知识以及遗传算法五个基本环节等遗传算法的相关知识。

第三章 基于学习分类器系统的智能体决策模型

3.1 引言

随着智能系统、分布式协同和群体智能等相关理论和技术的不断发展和突破，空中对抗正在向无人化、智能化和集群化转型。在战场中，单个无人机由于载荷小、对抗能力有限等局限性，无法独立完成任务，因此相关研究者提出了无人机集群对抗的模式。这种集群技术的研究主要源于蜂群的行为，通过每个个体执行简单任务并搭配群体策略使其整体表现出各种复杂行为。随着无人化技术的不断发展，无人机集群对抗已经成为未来战争的一个重要发展方向。在无人机集群对抗中，通过协同对抗、信息共享以及智能控制等手段，可以实现对目标的精确打击，进而提高对抗效率与灵活性，也为军事领域和民用领域的应用提供了无限可能。

在无人机集群决策与控制的研究中，基于人工智能算法的研究是当前研究的主要方向。但是由于神经网络结构复杂，其训练出的模型难以解释决策结果，不利于空战决策分析。这限制了深度学习、强化学习等算法在军事博弈等领域的应用，同时也影响了其在环境仿真、任务泛化等方面的普适性。因此，本章采用基于规则表示的学习分类器方法，设计了一种基于学习分类器系统的智能体决策模型，用于训练智能体决策策略。在无人机对抗场景中与基础规则方法进行实验对比，结果表明所构建的智能体决策模型在胜率上略有提升。

3.2 问题描述

本章的研究目标是在给定的军事对抗场景下，设计一种基于规则表示的红方智能体决策训练方法，使模型在保证对抗胜率的前提下具有较高的解释性。

为了便于对本章的研究问题进行解释，假设所有智能体的观察空间和动作空间是相同的。本节主要介绍联合对抗智能博弈对抗平台及实验场景设计。

3.2.1 联合对抗智能博弈对抗平台简介

联合对抗智能博弈对抗平台是模拟现实海陆空联合对抗复杂情景的仿真设计平台，其以红蓝双方对抗为核心，可以根据特定需求制定红蓝双方博弈策略，通过研究、设计和评估各种策略来应对不同的战场情况。

平台提供了全场景示意图，展示了对抗环境、战术布局以及可能的行动路径，如图 3-1 所示。用户可根据示意图中的情景制定策略，并通过模拟实验来评估策略的有效性。此外，平台还包括实时数据分析功能，帮助研究者更好的进行分析。

为了确保训练过程的有效性和对抗模拟的复杂性，考虑到海空对抗力量的高速移动和广阔的活动空间，将对抗空间范围设定在 $350\text{km} \times 350\text{km}$ 。对于红方，岛屿机场坐标为

(146700, -3000)；蓝方拥有两个指挥所，北部岛屿指挥所坐标为(-129532, 87667)，南部岛屿指挥所的坐标是(-131154, -87888)。此外，设置单局仿真时间为 2.5 小时，实际消耗时间由倍速决定。



图 3-1 联合对抗智能博弈对抗全场景

此平台中参与对抗的单位涵盖了海、陆、空三个领域的对抗力量。空中对抗力量以歼击机为主导，其携带的 6 枚空对空导弹用于对抗敌方飞行器，是空中对抗的核心；预警机承担情报收集的角色，利用其先进的探测技术在安全范围内提供情报支持；轰炸机用于对敌方防空单位和地面目标实施打击；干扰机则具备电子干扰能力，可在一定范围内干扰敌方雷达系统，保护本方飞行器免受敌方威胁。值得注意的是，干扰机的干扰范围会随着其接近敌方机场逐渐减小，增加了战术部署的复杂性。海上战斗力量以驱逐舰为主，装备 36 枚地对空导弹对敌方飞机进行防空拦截。陆地对抗力量包括雷达、地对空导弹和炮塔，构建了完整的防空体系，用于探测、拦截和摧毁敌方飞行器。以上对抗单位协同对抗，形成了一个完备的战术网络，为双方的博弈提供了多样化的战略选择和挑战。本章中主要涉及的对抗单位详细信息如表 3-1 所示。

表 3-1 对抗单位基本信息

飞机类型	最高速度	探测/干扰 角度	探测/干扰 距离	攻击距离	弹药/数量
歼击机	300m/s	120 度	100km	80km	6 枚
预警机	255m/s	360 度	250km		

每个对抗单元都包括移动和非移动两类原始动作。根据单位类型不同，其非移动动作呈现出多样性。例如，歼击机的非移动动作是对敌方空中单位发动攻击，而轰炸机则专注于海面或地面单位的打击。舰艇主要拦截空中单位，预警机负责控制雷达的开启和关闭，而干扰机则执行电子干扰设备的开启和关闭。

与其他博弈对抗平台相比，此仿真平台中的对抗单元通过指令列表来行动，这种方式提供了集中管理和控制的机制。状态空间包含了对抗单位的多个属性，例如位置坐标 (x,y) 、高度、单位类型、受损程度、剩余弹药量、存活状态、所属军别、兵种分类、航向和速度。此外，对抗单位具有观测和信息共享的能力，能够获取自身观测范围内的信息，包括敌方飞机的类型和位置以及盟友单位的各种信息。联合对抗博弈对抗全场景的全局状态如表 3-2 所示。

表 3-2 联合对抗博弈对抗全场景的全局状态表

状态	类型	取值范围	物理意义
x 坐标	浮点型		对抗单位横坐标，单位：米
y 坐标	浮点型		对抗单位纵坐标，单位：米
高度	浮点型	0/8000	对抗单位的高度，单位：米
军别	布尔型	False/True	False 表示红方；True 表示蓝方
类型	整型		标识对抗单位为何种类型的标识
存活	布尔型	False/True	False 表示死亡；True 表示存活
速度	整型		飞机的移动速度，单位：米/秒
航向	整型	[0, 360)	飞机的航向，单位：度
受损比	整型	[0, 100]	对抗单位的受损百分比
剩余弹药量	整型		飞机剩余的导弹数量

通过合理调整红蓝双方对抗单位的配置和兵力部署，可以实现多种任务场景。本文将基于联合对抗智能博弈对抗平台的多种对抗任务，训练红方智能体策略，增强其战术应对性和灵活能力。

3.2.2 实验场景

本节基于联合对抗智能博弈对抗平台，设计空战博弈场景，红蓝双方各自 9 架战机，包括 1 架预警机和 8 架歼击机。在设计的战斗空间中，强调整体实力的均衡性和挑战性，并确保训练出的智能体模型能够在真实对抗场景中具备泛化能力。智能体发射的弹药命中情况符合特定的概率分布，没有设定明确的命中判定标准，这种设置旨在考验模型的推理能力，从而区别于传统的全规则决策方法。

预警机主要负责执行空中预警任务，仿真平台将根据设定参数自动生成巡航航线，引导预警机从机场起飞并按照规划的航线进入巡逻区域进行空中预警，一旦进入巡逻区域，预警机将自动启用雷达系统，以侦测探测范围内的空中目标，完成指定时间的巡逻后，预警机将关闭雷达系统并执行盘旋待命。在空中交战时，歼击机将根据仿真平台生成的拦截航线，对目标执行拦截打击任务，直至敌机被击落或歼击机耗尽导弹。在拦截过程中，仿真平台将控制歼击机的传感器使用和武器发射，当与目标距离小于 50 公里时，自动发射中距空空导弹。歼击机所发射的空对空导弹的命中概率取决于发射距离及目标的机动性。完成拦截任务后，歼击机将在原地附近执行盘旋等待下一指令。

空战博弈场景如图 3-2 所示。



图 3-2 空战博弈场景

预警机和歼击机的武器性能参数如表 3- 1 所示。飞机被一枚导弹击中即判为击毁，在对抗时间内，若剩余的红方智能体大于蓝方智能体，则判红方获胜，反之，蓝方获胜。

3.3 博弈对抗策略模型设计

针对智能体决策模型的可解释性问题，本节基于学习分类器系统构建规则库，搭建基于强化学习思想的分类器子系统以及基于遗传算法的规则发现子系统，对抗策略模型框架如图 3-3 所示。




图 3-3 基于学习分类器的对抗策略模型框架

- (1) 分类器子系统：表示此刻的分类器种群，实时匹配智能体决策规则，保存与环境交互获得的回报值，更新分类器适应度值。
- (2) 规则发现子系统：通过传统的遗传算法步骤产生新的分类器种群，对规则库进行更新，目的是产生更好的规则。

智能体每执行一步决策时，会调用分类器子系统进行规则匹配，激活对应分类器并执行相应动作，与环境交互后获取奖励值更新规则库。在训练指定轮数获取丰富的规则库后，模型调用规则发现子系统，基于遗传算法实现规则库的演化，进一步提高规则的多样性。

3.3.1 分类器子系统设计

分类器子系统核心设计思想是借鉴强化学习的探索方式，与环境不断进行交互，获得相应的回报值，进而更新使用的分类器规则。

系统中，每一个分类器都被视为一条规则，用 IF/THEN/FITNESS 的形式进行存储。IF 部分表示条件，THEN 表示动作，FITNESS 表示适应度值。采用二进制编码的方式来表示各个特征，如表 3-3 所示。在每个智能体执行决策时，保存此时的态势信息，输入到分类器子系统中，激活条件与当前输入态势信息匹配的分类器，并返回对应的动作，智能体进而执行相应的动作指令。当存在多个分类器与输入相匹配时，会激活适应度最高的规则，然后根据探索得到的奖励值更新对应分类器的适应度。

表 3-3 规则表示

IF(状态)	THEN(动作)	FITNESS(适应度值)
101011010	1010	1.0

针对本章的实验平台，红方智能体的状态参数包括：红方与蓝方智能体之间的距离 distance、航向角 Ψ 、携带弹药的数量 weapon， x 坐标， y 坐标。将这 5 个变量作为智能体决策规则的状态信息，距离，航向角， x 坐标， y 坐标都设计为 2 位编码，携带弹药的数量设计为 1 位编码。状态编码总计为 9 位编码，具体编码方式如表 3-4 到表 3-6 所示。动作参数包括：飞行方向和指令选择。将这 2 个变量作为智能体决策规则中的动作信息，飞行方向设计为 3 位编码，指令选择设计为 1 位编码。动作编码总计为 4 位编码，具体编码方式如表 3-7 到表 3-9 所示。

表 3-4 状态编码(2 位)

编码	距离/km	航向 $\Psi / (^{\circ})$	x 坐标/km	y 坐标/km
0 0	>240	>270	>175	>175
0 1	180~240	180~270	0~175	0~175
1 0	120~180	90~180	-175~0	-175~0
1 1	<120	<90	<-175	<-175

表 3-5 状态编码(1 位)

每个变量编码	weapon
0	>0
1	=0

表 3-6 状态编码示例

distance/km	航向 $\Psi /(^{\circ})$	weapon	x 坐标/km	y 坐标/km
0 0	0 0	0	0 0	0 0

表 3-7 动作编码 (3 位)

每个变量编码	direction/ $(^{\circ})$
0 0 0	0
0 0 1	45
0 1 0	90
0 1 1	135
1 0 0	180
1 0 1	225
1 1 0	270
1 1 1	315

表 3-8 动作编码 (1 位)

每个变量编码	指令选择
0	巡航指令
1	拦截指令

表 3-9 动作编码示例

direction/ $(^{\circ})$	指令选择
0 0 0	0

3.3.2 规则发现子系统设计

规则发现子系统的目的是在训练过程中产生新的规则，并替换掉规则库中适应度较低的规则，实现优胜略汰。规则发现子系统基于遗传算法实现规则进化，其在分类器子系统训练一定轮数，获得一定优秀规则样本后才执行。本节主要介绍遗传算子的设计。

3.3.2.1 选择算子

为了提高子种群的多样性以及优越性，选用锦标赛选择法。每次从种群中取出一定数量的个体进行竞赛，然后选择其中最好的一个进入子代种群，重复该操作，直到新的种群规模达到设定的子种群规模。

3.3.2.2 交叉算子

将子种群中每个个体分别作为父本，随机选择子种群中另一个体作为母本，采用一点交叉方式，随机选择交叉点，根据设定阈值交换交叉点前后的特征。经交叉算子后产生的子代个体适应度值为父母个体适应度的均值。

3.3.2.3 变异算子

由于分类器是由二进制编码的方式表示，通过随机选择变异点，对变异点的数值由 0 变为 1，由 1 变为 0，即可实现变异操作。

规则发现子系统具体执行步骤如下：

- (1) 根据选择算子选择当前种群中较优的 n 个个体组建初始子种群。
- (2) 对子种群使用交叉、变异算子，构建新的规则。
- (3) 更新子种群的适应度。
- (4) 将规则库中适应度最差的 n 个规则替换为子种群，完成规则发现操作。

3.3.3 规则评估机制设计

为了更好的利用训练过程中与环境交互获得的奖励值，评估规则库中每条规则的优劣，本节设计了规则评估机制，包括实时更新机制和全局回报分配机制两部分，如图 3-4 所示。




图 3-4 规则评估机制框图

3.3.3.1 实时更新机制

在空战过程中，每一次智能体决策都会更新态势状态，与环境交互后获得相应的回报值。在执行决策后，根据获得的回报值对当前所执行的规则的适应度值进行更新。适应度更新方式如下：

$$fitness = fitness_{old} + R_{rule} + R_{border} + R_{weapon} \quad (3.1)$$

设定

$$R_{rule} = \begin{cases} 0, & \text{指令为巡航指令} \\ 3, & \text{指令为攻击指令，到达可攻击范围} \\ -2.5, & \text{指令为攻击指令，未到达可攻击范围} \end{cases} \quad (3.2)$$

该部分为了鼓励智能体在到达可攻击范围时，选择攻击指令，在未到达可攻击范围时，选择巡航指令。为了防止训练过程中陷于局部最优情况，对于超出对抗范围，仍向远离对抗区域方向巡航的指令设置惩罚项 R_{border} ， $R_{border} = -5$ 。设定

$$R_{weapon} = \begin{cases} 1, & \text{距离大于120km, 弹药数大于0, 向前飞} \\ -1, & \text{距离大于120km, 弹药数大于0, 向后飞} \\ 1, & \text{距离大于120km, 弹药数小于1, 向后飞} \\ 3, & \text{距离小于120km, 弹药数小于1, 向后飞} \\ -3, & \text{距离小于120km, 弹药数小于1, 向前飞} \\ -0.5 * weapon, & \text{距离小于120km, 弹药数大于0, 向后飞} \end{cases} \quad (3.3)$$

R_{weapon} 奖励值大小与红方到蓝方战机距离、智能体运动方向和搭载的剩余弹药数有关，鼓励智能体在与智能体距离较大、弹药数充足的情况下向前巡航；当弹药数不足的情况下，调转方向回避敌机。在距离较小、弹药不足的情况下，躲避敌机的奖励值更大，向前巡航的惩罚项更大。另外，对于距离较小、弹药数充足却回避的行为，根据所搭载的剩余弹药数设置惩罚项。

3.3.3.2 全局回报分配机制

在一轮空战中，每个智能体将进行 n 轮决策，每次决策都会激活一条规则。规则被选取时，会从所有规则中选择与当前状态匹配且适应度最高的规则，并解码其对应的动作以执行决策。随后，根据新的态势关系进行态势评估，获得一个奖励值 R 。为了最大程度模拟真实战场，设定奖励值如下：

$$R = 0.01 * R_{time} * R_{loss} + R_{weapon} + R_{dis} \quad (3.4)$$

其中 $R_{time} = 2400 - sim_{time}$ ，为了鼓励红方战机在尽可能短的时间内击败蓝方战机。 R_{loss} 定义为单位时间内蓝方战机战损数量减去红方战机战损数量即 $R_{loss} = blue_{loss} - red_{loss}$ 。为了减缓奖励稀疏的问题，当蓝方战机与红方战机距离足够小且发射导弹时，增加 R_{dis} 奖励项， $R_{dis} = 0.5$ 。设置

$$R_{\text{weapon}} = \begin{cases} 0, & \text{向前飞} \\ 0.5, & \text{弹药不足回避} \\ -0.2 * \text{weapon}, & \text{弹药充足却向后飞} \end{cases} \quad (3.5)$$

R_{weapon} 最终计算八架智能体的总和，该项奖励值大小与智能体剩余弹药数和飞行方向有关。鼓励智能体在剩余弹药不足的情况下调转方向进行躲避，而在弹药充足的情况下向前飞行击落敌机。

待该轮空战的 n 次决策结束后，会得到 n 个回报值 $R_1, R_2, \dots, R_n$ ，设置

$$\text{reward}_{\text{update}} = \begin{cases} \text{reward}_{\text{avg}} + 0.08 * \text{Agent}_{\text{loss}} - 0.1 * \text{Enemy}_{\text{loss}}, & \text{Agent}_{\text{last}} \neq \text{Enemy}_{\text{last}} \\ \text{reward}_{\text{avg}} - 0.1 * \text{Agent}_{\text{loss}}, & \text{Agent}_{\text{last}} = \text{Enemy}_{\text{last}} \end{cases} \quad (3.6)$$

其中 $\text{reward}_{\text{avg}} = (R_1 + R_2 + \dots + R_n) / \text{steps}$ ，表示平均决策回报值。 $\text{reward}_{\text{update}}$ 与平均决策回报值和对抗结束时红方与蓝方剩余战机数有关，鼓励智能体在保护红方战机的前提下尽可能多的击败蓝方战机。

针对本轮对抗中所有激活的规则，按照 $\text{reward}_{\text{update}}$ 更新其对应的适应度值，主要目的是提高全局态势对每条规则的影响。

3.4 实验与分析

3.4.1 实验结果

本文在 Linux 操作系统下进行智能体训练，基于 python3.7 实现代码编程。使用 Docker 调用仿真环境。蓝方智能体采用内置预编规则，红方智能体使用 LCS 算法进行训练。

统计 4 种情况下的胜率、胜负比、我方智能体平均存活数量、敌方智能体平均存活数量以及我方与敌方平均存活数量比，如表 3-10 和表 3-11 所示。（注：由于对抗过程中会出现平局，胜率为胜场数/（胜场数+平局数+败场数），胜负比为胜场数/败场数）：

表 3-10 胜率统计表

算法	胜率/%	胜负比
基础规则	7.7	0.09
种群大小为 50000 只使用分类器子系统	48.3	1.09
种群大小为 100000 只使用分类器子系统	74.7	4.77
种群大小为 100000 增加规则发现子系统	72	5.27

表 3-11 智能体平均存活数量统计表

算法	我方智能体 平均存活数量	敌方智能体 平均存活数量	我方与敌方 平均存活数量比
基础规则	0.54	2.15	0.25
种群大小为 50000 只使用分类器子系统	1.03	0.84	1.23
种群大小为 100000 只使用分类器子系统	2.07	0.72	2.87
种群大小为 100000 增加规则发现子系统	2.3	0.87	2.64

对比只使用分类器子系统情况下，种群大小为 50000 和种群大小为 100000 的奖励值回报曲线如图 3-5 所示；对比种群大小均为 100000 时，只使用分类器子系统和增加规则发现子系统的奖励回报曲线如图 3-6 所示。

由图表可见，使用学习分类器系统训练的智能体对比采用基础规则的智能体在胜率、胜负比、智能体平均存活数量等指标上都有明显的提高。增加规则库大小，能大大提高对抗胜率，这是由于规则库大小增加后，同样状态下可选择的规则数增多，提高了规则更新的容错率。在增加规则发现子系统后，能小幅提高胜负比和我方智能体平均存活数量，但胜率有所下降，可以得出结论：规则发现子系统可以增加优势规则的数量，但无法直接影响胜率。




图 3-5 只使用分类器系统不同种群大小下奖励回报曲线图




图 3-6 种群大小为 100000 对比两个子系统

3.5 本章小结

本章在给定军事对抗场景下，设计了一种基于学习分类器的智能体决策模型。首先，介绍了模型结构，包括基于强化学习思想的分类器子系统以及基于遗传算法的规则发现子系统，并分别进行设计。模型通过分类器子系统指导智能体进行决策，规则发现子系统扩充规则库，提高决策的多样性。为了评估每个规则的优劣，结合实验场景设计了规则评估机制，包括实时更新机制以及全局回报分配机制，指导模型学习。最后，在空战博弈场景下进行实验验证。实验结果表明，本模型在对抗胜率、胜负比、智能体平均存活数量等指标上都有较为明显的提高，增加规则发现子系统能够提升我方优势规则的数量，提高了规则库的多样性。

第四章 基于规则的策略提取与解释深度强化学习模型

4.1 引言

深度神经网络因其隐藏层中采用的分布式表征，具有较强的泛化能力，在各个领域有着广泛应用^[77]。然而，隐藏层特征的复杂性导致模型难以解释，无法理解其决策依据。这种解释性不足问题不仅影响了深度学习网络本身，也延伸至深度强化学习，降低了算法的可信度和透明度，制约了人机增强技术的发展。可解释性在深度学习模型的设计和使用过程中具有重要意义，对于模型的设计者而言，模型的解释性越强，其获得的知识越清晰，就能使设计者更有效地参与到模型的设计和优化中，专业领域的用户则可以通过解释性模型了解其内部的逻辑结构，尤其当模型表现出色超越人类时，解释性模型能够帮助用户从模型中汲取知识，指导其在该领域的实践。

第三章采用传统学习分类器的方式对智能体决策策略进行训练，基于规则的方式描述智能体的每一步决策，提高了模型的内部可解释性。但是此方法在泛化性、有效性等方面还存在缺陷。因此，本章在已经训练好的强化学习模型基础上，进行策略提取，在保证模型效果的前提下，用解释性更强的决策树模型替代强化学习模型，并进一步提取其中的规则。

4.2 问题描述

在机器学习和人工智能领域，策略解释性是指能够清晰解释机器学习和人工智能算法以及模型的设计过程，包括决策逻辑和结果生成的原因。随着机器学习和人工智能技术的飞速发展，越来越多的决策和操作交由计算机程序自主执行。然而，由于这些算法的“黑盒”性质，其内部决策过程难以被理解和解释，模型的解释面临着挑战。这可能引发许多问题，例如缺乏透明度可能导致用户难以信任模型的决策，也可能使得研究人员难以理解模型的内在逻辑，从而限制了模型在实际应用中的可行性。因此，研究如何提高机器学习和人工智能算法模型的解释性，成为了当前亟需解决的问题。本节探究决策中的状态序列和决策结果之间的因果关系。

策略解释的核心问题是建立一种可解释的映射，将状态序列和决策结果联系起来^[78]。以单个智能体的决策过程为例，假设智能体的策略表示为 π ，那么智能体选择动作的概率为：

$$P(A) = \pi(A | s_0, s_1, \dots, s_t) \quad (4.1)$$

进一步策略解释表示为：

$$\max_{0 \leq t \leq T} \frac{\text{dist}(P_A, P'_A(X_\pi))}{\text{dist}(P_A, P_A^H)} \leq \delta \quad (4.2)$$

其中, X_π 代表对策略进行解释, 而 P'_A 则是人类在时刻 t 对智能体动作概率的预测值。如果在一定时间 T 内满足公式(4.2), 那么可以说 X_π 对策略 π 实现了 δ 程度的解释。因此, 策略解释的目标在于尽可能减小 δ 的值, δ 越小, 解释的程度越高。为实现这一目标, X_π 的呈现形式应该简单易懂, 过于复杂的结构会降低解释的效果。

对于模型而言, 解释性和泛化能力呈现一种相互制约的关系, 增强解释性通常需要以牺牲泛化能力为代价。神经网络具有较强的泛化能力但解释性较差, 而决策树模型解释性强但泛化能力较弱。因此, 本章在强化学习模型的基础上做策略提取, 用决策树的形式将强化学习模型的策略表示出来, 在保证泛化能力的前提下提高强化学习模型的可解释性。

4.3 策略提取与规则解释

本章提出的基于规则的策略提取与解释深度强化学习模型方法主要包括四个环节, 如图 4-1 所示。




图 4-1 基于规则的策略提取与解释强化学习模型框架

首先利用已训练好的强化学习模型不断与环境交互，产生博弈对抗信息，包括状态、动作和奖励值，构建数据库；其次对数据进行预处理，分为属性值与标签，基于博弈对抗数据库进行策略提取，将强化学习模型用决策树模型代替；然后对训练好的决策树模型进行验证，确保其对抗效能与强化学习模型相当，进一步对决策树模型进行规则提取；最后结合实验环境对提出的决策规则进行分析，形成相应的策略规则库，并搭建策略决策树。

接下来将详细介绍本章所用的强化学习模型、可验证性策略提取算法以及决策规则提取流程。

4.3.1 强化学习模型

强化学习是一种学习机制，智能体通过学习在不同环境状态下采取最佳行动的策略来最大化累积奖励。在强化学习框架下，智能体的决策过程被建模为马尔可夫决策过程。MDP 利用状态集合 S 和原始动作集合 A 描述环境和智能体之间的交互。

如图 4-2 所示，基于 MDP 的强化学习模型由环境和智能体组成，智能体包含状态感知器，动作选择器和策略学习器三个部分。在与环境交互过程中，智能体感知环境状态 s ，基于环境选择并执行动作 a ；环境在接收到动作后，状态从 s 转移到 s' ，并将奖励 r 返回给学习器。奖励 $r: S \times A \rightarrow \mathbf{R}$ ，用于训练智能体的策略 π 。

在 MDP 中，环境的下一时刻状态 s' 仅与该时刻状态 s 有关，而与之之前的状态无关。状态转移的概率可以表示为：

$$P_{ss'}^a = E(S_{t+1} = s' | S_t = s, A_t = a) \quad (4.3)$$




图 4-2 强化学习框架

本章中所用的强化学习模型使用 QMIX 算法进行训练。QMIX 算法^[40]是一种基于值的多智能体强化学习算法，采用集中式训练、分布式执行的框架，使用混合的价值函数来表示整个团队的价值函数，同时保持每个智能体的局部策略。QMIX 主要包括混合网络（Mixing Network）、智能体网络（Agent Network）和超网络（Hypernetwork）三个部分。如图 4-3 所示。



 图 4-3 QMIX 网络框架^[40]

图 (c) 中每个智能体使用一个循环神经网络学习其局部 Q 函数，输入为当前观测值和上一时刻的动作，输出为对应动作的 Q 值。图 (b) 中的混合网络接收各个智能体网络的输出作为输入，并根据权重对各个智能体的局部 Q 值进行组合，得到整个智能体团队的全局 Q 值。为了满足单调性约束，混合网络的权重被限制为非负数。

为了更充分地利用状态信息，引入了一个超网络，将状态作为输入，并输出混合网络的权重和偏移量。这样可以确保权重的非负性，并且通过非线性映射网络来得到偏移量，以进一步提高系统性能。

QMIX 的代价函数表示如下：

$$L(\theta) = \sum_{i=1}^b [(y_i^{tot} - Q_{tot}(\tau, a, s; \theta))^2] \quad (4.4)$$

$$y^{tot} = r + \gamma \max_{a'} \bar{Q}(\tau', a', s'; \bar{\theta}') \quad (4.5)$$

其中， b 表示从经验池中采样的样本数量， $\bar{Q}(\tau', a', s'; \bar{\theta}')$ 表示目标网络。

4.3.2 基于 VIPER 算法的决策树构建

可验证性策略提取算法 (Verifiability via Iterative Policy ExtRaction, VIPER) 的主要思想是基于模仿学习的方法，使用高性能的深度强化学习模型来指导训练，最终将强化学习模型策略提取成一个决策树策略^[79]。

模仿学习是一种监督学习的方法，通过专家策略获得训练数据，一般以观测值作为输入数据，以产生的动作作为标签，通过设计损失函数，对参数化的策略函数进行迭代学习。

Dataset Aggregation (DAGGER) 算法是经典的模仿学习算法，在每轮的迭代过程中，专家策略都会对当前策略采集的状态进行标记，随后将这些新标记的数据整合到数据库中，用于重新训练策略网络^[80]。通过这一机制，策略网络学习到的策略分布将逐渐接近数据库中的策略分布。但是，DAGGER 算法忽略了一点，专家网络不仅仅能指导策略网络在当前状态下做出最佳操作，还能够提供每个状态-动作对的累积奖励。针对这一问题，

Bastani 等人^[79]提出了一种新的模仿学习算法 Q-DAGGER，其将 Q 函数作为专家策略，生成标记数据。

设 (S, A, R, P) 是一个有限时间步的 MDP，其中 S 是状态集， A 是动作集，转移概率 $P: S \times A \times R \rightarrow [0, 1]$ （即 $P(s, a, s') = p(s' | s, a)$ ），以及奖励值 $R: S \times A \rightarrow \mathbf{R}$ 。给定一个策略 $\pi: S \rightarrow A$ ，对于给定时间 $t \in \{0, \dots, T-1\}$ ，状态 s 的价值函数被定义为从状态出发，使用策略 π 累计的奖励，即

$$\begin{aligned} V_t^{(\pi)}(s) &= E_{\pi}(G_t | S_t = s) \\ &= E_{\pi}(R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots | S_t = s) \\ &= R(s) + \sum_{s' \in S} P(s, \pi(s), s') V_{t+1}^{(\pi)}(s'). \end{aligned} \quad (4.6)$$

智能体采用动作 a 的动作价值表示为：

$$\begin{aligned} Q_t^{(\pi)}(s, a) &= E_{\pi}(G_t | S_t = s, A_t = a) \\ &= E_{\pi}(R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots | S_t = s, A_t = a) \\ &= R(s, a) + \sum_{s' \in S} P(s, a, s') V_{t+1}^{(\pi)}(s'). \end{aligned} \quad (4.7)$$

假设初始状态 $s_0 \in S$ ，在时间 t 的状态分布表示如下：

$$d_t^{(\pi)}(s) = \sum_{s' \in S} P(s', \pi(s'), s) d_{t-1}^{(\pi)}(s') \quad (4.8)$$

$J(\pi) = -V_0^{(\pi)}(s_0)$ 为策略 π 下从 s_0 出发的代价。训练的目标是通过专家策略学习到给定数据集中的最佳策略。

设置损失函数如下：

$$l_t(s, \pi) = V_t^{(\pi^*)}(s) - Q_t^{(\pi^*)}(s, \pi(s)) \quad (4.9)$$

基于价值函数和动作价值函数的差值作为损失函数的定义，用于模型学习的指导。

算法 4.1 可验证性策略提取算法

- 1: 初始化迭代次数 N ，采样轨迹数 M
 - 1: 初始化数据集 $D \leftarrow \phi$
 - 2: 初始化策略为强化学习模型策略 $\hat{\pi}_0 \leftarrow \pi^*$
 - 3: for $i = 1 : N$:
 - 4: 基于策略 $\hat{\pi}_{i-1}$ ，采样 M 个轨迹作为第 i 次的数据集 $D_i \leftarrow \{(s, \pi^*(s)) \sim d^{\hat{\pi}_{i-1}}\}$
 - 5: 合并数据集 $D \leftarrow D_i$
 - 6: 基于损失函数凸上界重采样数据集 $D' \leftarrow \{(s, a) \sim p((s, a)) \propto \tilde{l}(s) d(s, a) \in D\}$
 - 7: 利用重采样数据重新训练决策树策略 $\hat{\pi}_i \leftarrow \text{TrainDecisionTree}(D')$
 - 8: end for
 - 9: return 最优策略 $\hat{\pi}_0 \in \{\hat{\pi}_1, \dots, \hat{\pi}_N\}$
-

VIPER 算法的伪代码如算法 4.1 所示，使用 CART 算法在数据集 D 上训练决策树。设定初始策略 $\hat{\pi}_0$ 为专家策略即要提取的强化学习模型策略 π^* ，在每一轮迭代中根据上

一轮的策略 π_{i-1} 的状态分布采样 M 个轨迹作为第 i 次的数据集 D_i ，将 D_i 与数据集 D 合并，基于损失函数的凸上界重采样数据集，利用重采样的数据集训练决策树，最终获取最优策略 $\hat{\pi}_0 \in \{\hat{\pi}_1, \dots, \hat{\pi}_N\}$ 。

4.3.3 决策规则提取

通过提取出来的决策树，可以根据输入的态势信息得到适用的策略规则。从决策树的根节点出发。经过中间节点到叶子节点，这一条决策路径可以用 IF-THEN 的形式表示出来，视作一条策略规则。决策树的每个叶子节点都代表一条具体的策略规则，假设一棵决策树有 L 个叶子节点，那么就可以从中提取出 L 条决策规则，组成一个决策集 $Rule = \{rule_1, rule_2, \dots, rule_L\}$ 。

决策树规则提取流程如算法 4.2 所示。首先，根据给定的决策树，以及可能的输出格式，初始化一个空的规则集合 $Rule$ ，用于存储提取出的规则。通过深度优先搜索 (DFS) 的方法遍历决策树的每个节点，对遍历到的节点生成一个部分规则，如果当前节点为叶子节点，则将其类别作为最终规则的一部分；如果节点为非叶子节点，则将节点的判断条件包括特征和阈值添加到部分规则，并递归处理其左右子树。遍历完成后，获得提取出的规则集合 $Rule$ 。

这样提取出的规则中，可能存在很多冗余信息，为了提高规则集的简洁性和泛化能力，减少冗余信息，进一步对规则集进行合并。遍历集合 $Rule$ ，对于每条规则 $rule$ ，检查条件部分是否相似或存在包含关系。对于具有相似性的规则，将它们合并为一条更泛化的规则。

算法 4.2 决策规则提取算法

```

1: 初始化规则集合  $R$  为空集
2: 初始化条件相似性阈值  $\delta$ 
3: while 存在未处理的节点 do
4:   获取下一个未处理的节点  $Node$ 
5:   提取节点  $Node$  的条件部分作为条件  $C$ 
6:   提取节点  $Node$  的类别部分作为类别  $L$ 
7:   将规则  $(C, L)$  添加到规则集合  $R$  中
8: end while
9: for 每对规则  $(C1, L1)$  和  $(C2, L2)$  in  $R$ , 其中  $C1 \neq C2$  do
10:   if 类别部分  $L1 = L2$  and  $C1$  包含于  $C2$  or  $C2$  包含于  $C1$  do
11:     合并规则  $(C1, L1)$  和  $(C2, L2)$  成为一条更泛化的规则
12:   end if
13: end for
14: 返回合并后的规则集合  $R$ 

```

4.4 实验与分析

4.4.1 实验场景

本章基于联合对抗智能博弈对抗平台，构建了典型博弈对抗场景，如图 4-4 所示，旨在模拟当前海空联合对抗中的典型情景。该场景涉及多个对抗单位，与第三章介绍的空战博弈场景相比，对抗环境更为复杂。因此，这是一个典型的异构多智能体控制环境中的非对称博弈场景，具有较高的仿真挑战性和现实性。






图 4-4 防空对抗对抗示意图

红方防空单位设有四个攻击通道，在一次决策时，可以同时执行四次攻击指令。

根据蓝方策略以及胜负判定条件的不同，设置两种对抗环境，蓝方策略如图 4-5 所示。



(a)正面攻击



(b)多方向突击

图 4-5 蓝方策略示意图

4.4.2 实验内容

4.4.2.1 博弈对抗数据预处理

通过强化学习模型与环境的交互过程中获取博弈对抗数据。考虑到模型训练的有效性，状态变量设计为：十架蓝方智能体相对防空单位的 x 坐标、相对防空单位的 y 坐标、

智能体的类别、防空单位远距离弹药数、防空单位中距离弹药数、防空单位近距离弹药数、攻击次数和上一次的动作。总共 35 个状态变量。

为了进一步训练决策树，将上述状态信息进行预处理，如表 4- 1 所示：

强化学习模型的动作空间为[0,1,2,3,4,5,6,7,8,9,10]，其中 0-9 表示攻击第*i*个蓝方智能体，10 表示不攻击，将其作为决策树提取的类别标签。

表 4- 1 状态预处理

状态	类型	取值	预处理
<i>x</i> 坐标	连续		1:1000000 缩小
<i>y</i> 坐标	连续		1:1000000 缩小
类型	离散	1,2,3	1-高能战机，2-低能战机，3-干扰机
远距离弹药数	离散	[0,1]	离散归一化，将取值范围从 1-6 映射到 0-1 区间
中距离弹药数	离散	[0,1]	离散归一化，将取值范围从 1-6 映射到 0-1 区间
近距离弹药数	离散	[0,1]	离散归一化，将取值范围从 1-6 映射到 0-1 区间
攻击次数	离散	[0,1]	离散归一化，将取值范围从 0-3 映射到 0-1 区间
上一次攻击	离散	0-10	上一次决策动作，为 0-10 的整数

4.4.2.2 基于规则的策略提取和解释强化学习模型

基于规则的近似与解释强化学习模型过程主要有数据收集与预处理、CART 分类决策树构建、模型评估及决策树可视化和策略规则提取四个环节。首先通过强化学习模型与环境交互获取博弈对抗数据，经过预处理后组成数据库并与原先数据库合并，在每一局对抗结束后，调用 VIPER 算法根据当前的数据库构建 CART 分类决策树。由于环境设置，数据库中样本数据不均衡，为了解决这一问题，在采样时根据类别设置权重如表 4-2 所示。

表 4-2 采样权重设置

类别	权重
攻击指令	8
不攻击指令	1

训练完成后，对构建的决策树进行评估，验证模型的有效性，确保红方胜率、防空单位受损程度、击落敌机数量等性能指标与强化学习模型近似。为了进一步理解和可视化决策树，采用策略规则提取方法将决策树中隐藏的因果逻辑提取出来，用 IF-THEN 规则的形式表示，并构建博弈对抗策略树。

4.4.3 实验一结果


4.4.3.1 策略有效性

分别采用提取出的决策树模型和 QMIX 强化学习模型进行 1000 局对抗，来验证策略有效性。由表 4-3 可以看出，决策树模型的胜率相较于 QMIX 模型有较大的提升，这可能归因于策略提取时采样权重的设置，能够减少数据库中的干扰项，提高策略的有效性。


表 4-3 实验一对抗胜率对比

模型	胜局数	败局数	胜率
决策树	884	116	88.4%
QMIX	772	228	77.2%

图 4-6 所示为决策树模型和强化学习模型在蓝方为正面攻击策略对抗环境下的红方对抗效能对比图。图（a）为当前轮数下计算前 50 轮的对战胜率，从图（a）和图（b）可以看出在此对抗环境下，决策树模型能够在尽可能保护自身的前提下提高胜率。



（a）红方防空单位对战胜率曲线



（b）红方防空单位受损情况

图 4-6 红方防空单位对战胜率与受损情况

图 4-7 描述了红方防空单位在对抗中的表现，包括击落敌机数量、击落高能战机数量以及击落低能战机数量。根据胜负判定条件以及实验结果表明，决策树模型倾向于执行优先击落高能战机的策略。




图 4-7 击落敌机数量情况

4.4.3.2 策略解释性

由于提取出的决策树过大，无法进行展示，因此根据节点将决策树分裂为子树，如图 4-8 所示为 41 号节点部分子树示意图。其中节点颜色不同表示标签不同，每个节点包括判断特征、分裂阈值、不同标签的采样值等信息。

在对抗过程中，由于强化学习模型未执行 8 和 9 动作，获取的数据库中数据的标签只有[0,1,2,3,4,5,6,7,10]，分别代表攻击一号飞机，攻击二号飞机、攻击三号飞机、攻击四号飞机、攻击五号飞机、攻击六号飞机、攻击七号飞机、攻击八号飞机以及不攻击指令。

为了更好地描述规则，对距离特征进行离散化表述，考虑到实验场景设置，离散化对应如下：{相对 X 距离小于-300km， “相对 X 远”}，{相对 X 距离大于-300km 小于-150km， “相对 X 较远”}，{相对 X 距离大于-150km 小于-75km， “相对 X 较近”}，{相对 X 距离大于-75km 小于 75km， “相对 X 近”}，{相对 X 距离大于 75km， “相对 X 超过”}，{相对 Y 距离绝对值大于 100km “相对 Y 远”}，{相对 Y 距离绝对值大于 50km 小于 100km “相对 Y 较远”}，{相对 Y 距离绝对值小于 50km “相对 Y 较近”}。




图 4-8 蓝方正面攻击下红方防空单位决策树可视化示意图

对该决策树进行规则提取，获取决策规则如表 4-7 所示。

表 4-4 实验一决策树提取的决策规则表

序号	决策规则
1	IF 一号飞机相对 X 不近；三号飞机相对 Y 远 THEN 攻击三号飞机
2	IF 一号飞机相对 X 不近；二号飞机相对 X 远；决策次数小于等于两次 THEN 不攻击
3	IF 一号飞机相对 X 不近，相对 Y 远；二号飞机相对 X 远；三号飞机相对 Y 较远 THEN 攻击一号飞机
4	IF 一号飞机相对 X 不近；二号飞机相对 X 较近；三号飞机相对 Y 较远；上一次决策为攻击一号飞机 THEN 攻击二号飞机
5	IF 一号飞机相对 X 不近；二号飞机相对 X 较近；三号飞机相对 Y 较远；上一次决策没有攻击一号飞机；近距弹药数充足 THEN 攻击二号飞机
6	IF 一号飞机相对 X 不近；二号飞机相对 X 近；三号飞机相对 X 远 THEN 攻击一号飞机
7	IF 一号飞机相对 X 不近；二号、七号、五号飞机相对 X 远；当轮未攻击 THEN 攻击二号飞机
8	IF 一号飞机相对 X 近，三号飞机相对 X 较近；四号飞机相对 X 远；当轮未攻击 THEN 攻击四号飞机
9	IF 一号飞机相对 X 近，三号飞机相对 X 较近；四号飞机相对 X 远；当轮已攻击；上一次决策为攻击四号飞机 THEN 攻击三号飞机
10	IF 一号飞机相对 X 近，三号飞机相对 X 近；二号飞机相对 X 远；当轮未攻击 THEN 攻击二号飞机
11	IF 一号飞机相对 X 近，三号飞机相对 X 近；二号飞机相对 X 远，四号飞机相对远，七号飞机相对 Y 较远；上一次决策为攻击六号飞机 THEN 攻击六号飞机

由于该实验场景下相对 Y 距离绝对值大于 100km 的情况不会出现，结合场景设置对上述决策规则进一步精简，可以总结出以下几条策略规则：

表 4-5 策略规则表

序号	策略规则
1	IF 相对一号、三号攻击距离优势弱 AND 决策次数少 THEN 不攻击
2	IF 相对一号、三号攻击距离优势弱 AND 决策次数多 THEN 攻击一号飞机
3	IF 相对一号、三号攻击距离优势均 AND 上次决策指令为一号 THEN 攻击一号飞机
4	IF 相对一号、三号攻击距离优势均 AND 上次决策指令非一号 THEN 攻击二号飞机
5	IF 相对一号、三号攻击距离优势强 AND 相对其余飞机攻击距离优势弱 AND 上次决策指令包括六号 THEN 攻击六号飞机
6	IF 相对一号、三号攻击距离优势强 AND 相对四号飞机攻击优势弱 AND 决策次数少 THEN 攻击四号飞机
7	IF 相对一号、三号攻击距离优势强 AND 相对四号飞机攻击优势弱 AND 上次决策指令包括四号 THEN 攻击三号飞机
8	IF 相对一号、三号攻击距离优势强 AND 相对二号飞机攻击优势弱 AND 决策次数少 THEN 攻击二号飞机

基于上述策略规则，构建博弈对抗策略决策树如图 4-9 所示。




图 4-9 蓝方正面攻击博弈对抗策略决策树

4.4.4 实验二结果


4.4.4.1 策略有效性

分别采用提取出的决策树模型和 QMIX 强化学习模型进行 1000 局对抗，来验证策略有效性。对抗结果如表 4-9 所示，决策树模型相较强化学习模型在对抗胜率上有一定的提升。对比表 4-6 和表 4-9 可以看出，蓝方策略以及胜负判定不同的情况下，红方防空单位的策略有效性也有所区别，在蓝方为多方向突击策略以及记分胜负判定设置下，对抗环境更为复杂，强化学习训练出的模型策略有效性更好，对抗胜率更高。


如图 4-10 所示为决策树模型和强化学习模型在蓝方为多方向突击策略对抗环境下的对抗效能对比图，可以看出在此对抗环境下，决策树模型能够在尽可能保护自身的前提下提高胜率。图 4-11 描述了红方防空单位在对抗中的表现，包括击落敌机数量、击落高能战机数量以及击落低能战机数量，可以看出强化学习模型能够击落更多的敌机数量，但是对于高能战机，决策树模型可以保证每轮对决中都将其击落。

表 4-6 实验二对抗胜率对比

模型	胜局数	平局数	败局数	胜率
决策树	988	8	4	98.8%
QMIX	919	23	58	91.9%




(a) 红方防空单位对战胜率曲线




(b) 红方防空单位受损情况


图 4-10 红方防空单位对战胜率与受损情况



(a) 击落敌机数量情况



(b) 击落高能战机数量情况



(c) 击落低能战机数量情况

图 4-11 击落敌机数量情况

4.4.4.2 策略解释性

提取出的决策树根据节点分裂成子树,61号节点的部分子树可视化如图4-12所示。




图 4-12 蓝方多方向突击下红方防空单位决策树可视化示意图

对比实验二与实验一的决策树模型，可以看出，在实验一场景下，决策树模型更多执行不攻击的动作，而在实验二场景下，决策树模型叶子节点标签更为丰富，在决策过程中能够执行更多不同的动作，其决策策略也相对更为复杂。

在实验二场景下，红方防空单位由于其决策策略多样性，能够实现多样的攻击指令，拦截更多的敌方战机，进而提高对抗胜率。

对该决策树进行规则提取，获取决策规则如表 4-10 所示。

表 4-7 实验二决策树提取的决策规则表

序号	决策规则
1	IF 大多数飞机距离远 THEN 不攻击
2	IF 二号飞机相对 Y 较远，五号飞机相对 X 远，三号飞机相对 Y 不远 THEN 攻击三号飞机
3	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮未攻击，六号飞机相对 X 不远；五号飞机相对 Y 在防空单位上方 THEN 不攻击
4	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮未攻击，六号飞机相对 X 远，五号飞机相对 Y 在防空单位下方 THEN 攻击五号飞机
5	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮未攻击，六号飞机相对 X 不远，一号飞机相对 Y 不远 THEN 攻击一号飞机
6	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮未攻击，六号飞机相对 X 不远，一号飞机相对 Y 远，五号飞机相对 Y 近 THEN 攻击五号飞机
7	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮已攻击，上次攻击为一到五号飞机，六号飞机相对 X 远 THEN 不攻击
8	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮已攻击，上次攻击为一到五号飞机，六号飞机相对 X 不远 THEN 攻击六号飞机
9	IF 二号飞机相对 Y 较远，五号飞机相对 X 不远，当轮已攻击，上次攻击非一到五号飞机 THEN 不攻击
10	IF 二号飞机相对 Y 近，远距弹药数不足，当轮未攻击 THEN 攻击二号飞机
11	IF 二号飞机相对 Y 近，远距弹药数充足，三号飞机相对 Y 较远，七号飞机不在探测范围内 THEN 攻击六号飞机
12	IF 二号飞机相对 Y 近，远距弹药数充足，三号飞机相对 Y 较远，七号飞机在探测范围内，当前未攻击 THEN 攻击七号飞机
13	IF 二号飞机相对 Y 近，远距弹药数充足，三号飞机相对 Y 较远，七号飞机在探测范围内，上次决策为攻击指令 THEN 攻击六号飞机
14	IF 四号飞机在探测范围内，三号飞机不在探测范围内，上次未攻击四号飞机 THEN 攻击四号飞机
15	IF 四号飞机在探测范围内，三号飞机在探测范围内，当前未决策 THEN 攻击三号飞机

- 16 IF 四号飞机在探测范围内, 三号飞机在探测范围内, 决策三次以上 THEN 攻击四号飞机
- 17 IF 四号飞机在探测范围内, 三号飞机在探测范围内, 决策一次或两次, 上次未攻击三号飞机 THEN 攻击三号飞机
- 18 IF 四号飞机在探测范围内, 三号飞机在探测范围内, 决策一次或两次, 上次攻击一到三号飞机 THEN 攻击四号飞机

结合场景设置对上述决策规则进一步精简, 可以获得相应的策略规则, 此处不再赘述, 构建博弈对抗策略决策树如图 4-12 所示。

相较于蓝方正面攻击的环境, 此环境下由于蓝方策略更为复杂, 红方防空单位的策略规则也更加复杂, 红方决策中增加多种情况下的攻击指令, 以实现更大的对抗胜率。




图 4-13 蓝方多方向突击博弈对抗策略决策树

4.5 本章小结

本章针对强化学习可解释性问题, 提出了一种基于规则的策略提取与解释深度强化学习模型的方法。首先介绍了本章所使用的强化学习模型, 采用可验证性策略提取算法提取强化学习模型策略, 并将其用决策树的形式表示, 提取其中的决策规则, 进一步解释决策树。在典型博弈对抗场景下, 针对两种蓝方策略进行实验, 所提取的决策树在对抗效能上与强化学习模型相媲美, 在对抗胜率上都有大幅度提高。此外, 通过对决策树的规则提取与分析, 获取给定实验场景下的策略规则表, 大大提高了模型的可解释性, 构建了博弈对抗决策树, 对现实军事对抗提供了借鉴意义。然而如何在保证对抗效能的前提下, 获得更多的决策策略, 扩充策略库是一个需要进一步研究的问题。

第五章 基于遗传算法的决策树演化

5.1 引言

决策树等知识驱动方法基于已有知识和完备的理论体系，在模型的稳定性、收敛性和可解释性方面有着天然的优势，通过充分利用专家知识和经验，将问题分解为一系列决策节点，从而生成可解释性强、易于理解的决策模型。此外，知识作为数据和信息的高度凝练，往往具有更高的执行效率。进化算法、强化学习等数据驱动方法能够实现解空间的大范围探索，从数据中持续学习和进化，往往能得到知识之外的解决方式。这些方法适用于处理大规模、复杂的问题，并能够在不断的迭代中提升性能。因此，如何将知识驱动方法和数据驱动方法结合起来，利用各自优势，形成知识与数据协同驱动的新模式，是目前多智能体系统研究的重要方向之一。

第四章对训练好的强化学习模型进行策略提取，用决策树的形式近似和解释强化学习模型，形成了指定环境下的专家决策树。为了进一步对该决策树优化，形成更多的策略规则，本章设计了一种基于遗传算法的决策树演化方法，将知识与数据相结合，通过遗传算法探索解空间，提高决策多样性。

5.2 问题描述

本章旨在通过遗传算法对第四章获取的决策树模型进行演化，以获得更多的战术规则。存在的问题如下：

第一，遗传算法中的个体一般采用编码的形式表示，传统的编码方式可能会过于简化，导致决策树的决策信息丢失。因此，需要设计合适的个体表示方法，以充分保留决策树的结构和决策信息，从而确保演化过程的有效性和结果的可靠性。

第二，复杂的博弈对抗场景中，智能体的决策受到各种限制，决策动作值会因态势信息缺失出现无效指令，在演化算子的设计上存在困难。

第三、决策树模型体现的是整体决策规则，因此在动作选择和适应度评估时需要考虑全局状态的影响。

5.3 决策树演化设计

针对决策树进化问题，本章设计了一种基于遗传算法的决策树演化模型。选用专家决策树构建初始种群，设计决策树评估机制，在每一轮对抗过程中，选取当前种群中最优个体进行决策，在与环境交互后，根据决策树评估机制对当前个体适应度值进行更新。在每轮对抗结束后，通过遗传操作对种群实现演化。在设定的对抗次数训练完成后，获取当前最优个体，进行策略提取与分析。

基于遗传算法的决策树演化流程图如图 5-1 所示。




图 5-1 基于遗传算法的演化流程示意图

5.3.1 染色体编码与种群初始化

专家决策树模型是以二进制的格式存储。为了充分保留决策树形式与相关决策信息，染色体个体以决策树编码形式表示。在初始化阶段，读取专家决策树模型，构建 N 个个体，每个个体由唯一的序号、决策树模型和其对应的适应度值组成，如表 5-1 所示。

表 5-1 个体组成示例

ID	决策树	Fitness
1	Tree	20

初始种群中，N 个个体除序号外均保持一致，这样的设计保留了专家模型指导。由于初始种群的决策树模型直接基于专家模型构建，因此在适应度评估时，这些个体具有较高的起始适应度值，有助于优化算法的快速收敛和优化性能的提升。

5.3.2 遗传操作设计

5.3.2.1 选择算子

为了尽可能保留父代中的优秀个体，并提高探索空间，采用锦标赛选择算子选择后代。首先，随机选择一定数量的个体，称为锦标赛中的竞争者，然后从中选出表现最优的个体作为后代的父母。这样的选择过程重复进行，直到得到足够数量的后代个体。

在锦标赛选择算子中，通过设置合适的竞争者数量和比较规则，可以有效地保留父代中的优秀个体，并引入一定程度的随机性，增加探索空间。通过随机选择竞争者，可以避免过度依赖单一的优秀个体，促进种群和进化的多样性。

5.3.2.2 交叉算子

由于个体编码为决策树形式，如果更改决策树结构有可能使决策树模型畸变，失去可靠性。因此选用基础的一点交叉算子，交叉过程如图 5-2 所示。随机选择决策树节点，交换两棵树中该节点的子树。这种交叉操作有助于在保持决策树结构的同时，引入新的变化，从而推动种群的进化和优化。




图 5-2 决策树交叉示意图

5.3.2.3 变异算子

决策树的每个节点包含特征、阈值，标签等信息，根据变异程度不同，设置阈值突变和标签突变两种方式。

(1) 阈值突变

对阈值按照指定范围增加或减少，便可达到突变的效果。根据第四章的设置以及专家决策树节点信息，具体特征突变范围如表 5-2 所示。其中，对于 x, y 坐标，当其小于 -0.2 时，已经超出红方防空单位的攻击范围，因此将该特征向正向突变且突变范围较大。在每次遗传操作时，子代个体随机选择 m 个结点突变。

表 5-2 各特征突变范围

特征	突变范围
x, y 坐标 < -0.2	$[0, 0.3]$
$-0.2 < x, y$ 坐标 < 0	$[0, 0.1]$
x, y 坐标 > 0	$[-0.1, 0.1]$
类型	$[-1, 1]$
远距离弹药数	$[-0.1, 0.1]$

中距离弹药数	$[-0.1,0.1]$
近距离弹药数	$[-0.1,0.1]$
攻击次数	$[-0.1,0.1]$
上一次攻击	$[-1,1]$

(2) 标签突变

决策树的每个节点都会有不同标签的样本采样值，选择样本中出现次数最多的类别作为该节点的标签。通过随机交换不同标签的样本采样值，可以实现标签突变，如图 5-3 所示。




图 5-3 标签突变示意图

5.3.3 决策树评估机制

为了更好地利用训练过程中与环境交互获得的回报值，评估种群中个体的优劣，本节设计了决策树评估机制，包括实时更新机制和全局回报分配机制两部分，如图 5-4 所示。




图 5-4 决策树评估机制示意图

由于决策树体现的是整体决策，相较于第三章学习分类器每步决策都选择当前最优的个体执行，本章中每个决策树执行十步决策后，再重新根据适应度值选择当前最优个体，保障决策树个体的决策完整性。

5.3.3.1 实时更新机制

在对抗过程中，每一次智能体决策都会更新态势状态，与环境交互后获得相应的回报值。在每一步执行决策后，根据获得的回报值对当前所执行的决策树的适应度值进行更新。适应度更新方式如下：

$$fitness = fitness_{old} + R_{bigshot} + R_{smallshot} + R_{jamshot} + R_{rule} \quad (5.1)$$

其中 $R_{bigshot}$ 为当前决策击落高能战机奖励， $R_{smallshot}$ 为当前决策击落低能战机奖励， $R_{jamshot}$ 当前决策击落干扰机奖励。根据威胁程度不同，对三种敌机的击落设置不同的权重，高能战机赋值 10 分，低能战机赋值 1 分，干扰机赋值 5 分。由于环境设置，当红方防空单位没有蓝方智能体信息但选择攻击该智能体时，为无效攻击指令，故对出现无效指令的决策树增加 R_{rule} 惩罚项。具体计算公式如下：

$$\begin{aligned} R_{bigshot} &= 10 * (buleBig_{last} - buleBig) \\ R_{smallshot} &= 1 * (buleSmall_{last} - buleSmall) \\ R_{jamshot} &= 5 * (buleJam_{last} - buleJam) \\ R_{rule} &= -100 \end{aligned} \quad (5.2)$$

5.3.3.2 全局对抗结果评估机制

为了提高全局对抗情况对决策树优劣的影响，根据每局对抗结束后的战损情况设置全局奖励，对本局对抗中所有参与决策的决策树适应度值进行更新，更新公式如下：

$$\begin{aligned} fitness &= fitness_{old} + R_{da} \\ R_{da} &= 100 * blue_{da} + 70 * red_{da} \\ bule_{da} &= 1 - (10 * blue_{big} + blue_{small} + 5 * blue_{jam}) / 36 \\ red_{da} &= red_{loss} * 0.5 + red_{das} \end{aligned} \quad (5.3)$$

R_{da} 的设定是为了指导决策树模型策略在尽可能多拦截对方智能体的前提下，降低自身损耗。蓝方战损根据打落的战机按照高能 10 分，低能 1 分，干扰机 5 分进行赋值计算，红方战损中 red_{das} 可以从环境态势中获得，如果某防空单位被击落，获取的 red_{das} 中没有该防空单位的战损信息，因此增加 red_{loss} 项表示击落防空单位战损。 R_{da} 对红蓝双方战损设置不同的权重，蓝方战损赋值 100，红方战损赋值 70。

5.4 实验与分析

本节实验选用第四章中蓝方策略为正面攻击的实验场景，将红方决策树模型作为专家决策树，进一步实现演化。

5.4.1 实验参数设定

为了获取更多的策略规则，设定两组不同的实验参数进行对比实验。具体参数设定如表 5-3 所示。

表 5-3 实验参数设定

实验组别	参数	参数设置	突变机制
实验一	种群大小	40	加入阈值突变和标签突变
	后代大小	6	
	突变结点数量	5	
实验二	种群大小	60	加入阈值突变和标签突变
	后代大小	6	
	突变结点数量	5	

5.4.2 策略有效性

实验一、实验二演化训练情况如图 5-5 和图 5-6 所示，初始种群个体均为专家决策树，策略胜率较高，在演化训练过程中，由于遗传的不确定性，胜率会逐渐减少，根据对抗结果选取其中效果较好的决策树进行测试。




图 5-5 实验一演化训练胜率图




图 5-6 实验二演化训练胜率图

实验一选择第 54 代决策树模型，实验二选择第 15 代决策树模型。分别用演化后的模型和专家决策树模型进行 1000 局对抗，验证其策略有效性。胜负判定标准通过蓝方高能战机存亡和红方防空单位存活情况来界定：当蓝方高能战机被摧毁且红方存活时，红方胜；当蓝方高能战机存活，或者红方单位被摧毁时，蓝方胜。表 5-4 为专家决策树、实验一演化决策树和实验二演化决策树的对抗胜率对比，可以看出，经过演化后的决策树，在对抗胜率上都有一定的提高。

表 5-4 对抗胜率对比

模型	胜局数	败局数	胜率
专家决策树	884	116	88.4%
实验一演化决策树	937	63	93.7%
实验二演化决策树	929	71	92.9%

图 5-7 为实验一演化决策树模型与专家决策树模型之间的红方防空单位对抗胜率和受损情况对比图。演化后的决策树模型能够在保护我方单位战损的前提下提高对抗胜率。图 5-8 中可以看出，演化后的决策树模型能够打击更多的敌方战机，主要是对于低能战机的拦截。相比之下，演化后模型的对抗效能有一定提升。




图 5-7 实验一演化模型红方防空单位对抗胜率 and 受损情况对比




图 5-8 实验一演化模型击落敌机数量情况




图 5-9 实验二演化模型红方防空单位对抗胜率 and 受损情况对比




图 5-10 实验二演化模型击落敌机数量情况

图 5-9 为实验二演化决策树模型与专家决策树模型之间的红方防空单位对抗胜率和受损情况对比。演化后的决策树模型同样能够在保护我方单位战损的前提下，提高对抗胜率。从图 5-10 中可以看出，实验二演化后的决策树模型在敌方战机拦截数上有较大的提升，其能够在保证高能战机击落的前提下，拦截更多的低能战机。通过对比图 5-8 和图 5-10 可以看出，实验二获得的演化决策树模型对抗效能更好，这是由于提高了种群数量，促使种群演化过程中发现更好的决策策略。

5.4.3 策略提取效果对比

5.4.3.1 实验一

对实验一中演化的第 54 代决策树进行规则提取，对比专家决策树，获取的新增决策规则如表 5-5 所示。

表 5-5 新增决策规则

序号	决策规则
1	IF 一号飞机相对 X 不近；三号飞机相对 Y 较远；上一次决策为攻击一号飞机 THEN 攻击四号飞机
2	IF 一号飞机相对 X 不近；二号飞机相对 X 较近；三号飞机相对 Y 较远；上一次决策没有攻击一号飞机；近距弹药数不足 THEN 攻击六号飞机

- 3 IF 一号飞机相对 X 不近；二号飞机相对 X 远；三号飞机相对 Y 较远；五号飞机相对 Y 远 THEN 攻击五号飞机
- 4 IF 一号飞机相对 X 不近；二号飞机相对 X 远；三号飞机相对 Y 较远；五号飞机相对 Y 较远；七号飞机相对 X 近；远距弹药数充足 THEN 攻击七号飞机
- 5 IF 一号飞机相对 X 不近；二号飞机相对 X 远；三号飞机相对 Y 较远；五号飞机相对 Y 较远；七号飞机相对 X 较近；远距弹药数充足 THEN 攻击一号飞机
- 6 IF 一号飞机相对 X 不近；二号飞机相对 Y 远；三号飞机相对 Y 远；上次攻击七号八号飞机或不攻击；近距弹药数无损耗 THEN 攻击三号飞机
- 7 IF 一号飞机相对 X 不近；二号飞机相对 Y 远；三号飞机相对 Y 远；上次攻击七号八号飞机或不攻击；近距弹药数有损耗 THEN 攻击四号飞机
- 8 IF 一号飞机相对 X 近，三号飞机相对 X 近；二号飞机相对 X 远，四号飞机相对远，七号飞机相对 Y 较远；上一次攻击一号到六号飞机 THEN 攻击六号飞机
- 9 IF 一号飞机相对 X 近，三号飞机相对 X 近；二号飞机相对 X 远，四号飞机相对远，七号飞机相对 Y 近；六号飞机相对 Y 远 THEN 攻击二号飞机
- 10 IF 一号飞机相对 X 近，一号飞机类型为高能战机，三号飞机相对 X 近；二号飞机相对 X 远，四号飞机相对远，七号飞机相对 Y 较远；上一次未攻击五号；攻击次数剩余两次 THEN 攻击五号飞机

相较于专家决策树，增加攻击五号、攻击七号的决策规则。结合场景设置对上述决策规则进一步精简，可以将其中的策略规则用一个博弈对抗策略决策树表示，如图 5-11 所示。




图 5-11 实验一博弈对抗策略决策树

5.5 本章小结

本章为了实现知识与数据协同驱动，扩充策略规则库，提出了一种基于遗传算法的决策树演化方法。首先介绍了染色体编码和种群初始化方式，其次根据环境设置，设计遗传算子以及决策树评估机制指导决策树演化。在典型博弈对抗场景下，根据遗传参数设定不同，进行两组对照实验。从两组实验中分别选择效果最好的决策树进行对抗效能评估。演化后的决策树在对抗效能上都有不同程度的提高。此外，通过对决策树的规则提取与分析，和第四章的决策规则对比，获取新增的决策规则表，并构建博弈对抗决策树，进一步扩充了策略规则库。

第六章 总结与展望

6.1 全文总结

当代战争环境下,随着军事科技的发展和现代战争的特点日益凸显,对军事指挥决策提出了更高的要求。人工智能技术的引入对提升指挥部决策速度、各军种的协同配合具有重要意义。与此同时,由于深度神经网络的“黑盒”特性,使得模型可解释性成为一个重要议题。基于此背景,本文以规则演化理论为基础,结合军事博弈现实需求,以知识与数据相结合的训练方法研究多智能体博弈对抗场景中的策略学习问题,旨在提高模型的可解释性和有效性,增强智能体的效率和灵活性,为军事指挥控制决策提供更加准确、全面和适应性强的指导方案。主要研究成果如下:

(1) 针对智能体决策模型内部可解释性不足的问题,基于规则表示的学习分类器方法学习智能体决策策略。通过设计基于学习分类器的智能体决策模型,包括分类器子系统和规则发现子系统两部分,实现了智能体决策和规则库的扩充;设计规则评估机制,指导决策模型学习。在实验验证中,该模型在空战博弈场景下表现出明显的提升,包括对抗胜率、胜负比、智能体平均存活数量等指标。并且由于模型本身是用规则的方式进行表示,具有较强的可解释性。

(2) 针对深度强化学习模型的可解释性不足问题,提出了基于规则的策略提取与解释深度强化学习模型策略的方法。通过强化学习模型与环境交互获取博弈对抗数据,利用可验证性策略提取算法提取模型策略,并以决策树的形式表示。在典型博弈对抗场景下,对两种不同的蓝方策略进行实验验证,所提取的决策树模型在对抗效能上与强化学习模型相媲美,并在对抗胜率上有所提高。通过对决策树模型的规则提取与分析,得到了在给定实验场景下的策略规则表,提高了模型的可解释性,为现实军事对抗提供了借鉴意义。

(3) 为了进一步优化决策树,扩充策略规则库,提出了一种基于遗传算法的决策树演化方法,实现知识驱动与数据驱动方法相融合。该方法利用遗传算法探索解空间,提高决策多样性,并在典型博弈对抗场景下进行实验验证。实验结果表明,演化后的决策树模型在对抗效能上都有不同程度的提高。同时,通过对决策树模型的规则提取与分析,获取新增的策略规则表,构建了博弈对抗决策树,进一步扩充了策略规则库。

6.2 讨论与展望

多智能体博弈对抗策略研究因其涉及数据复杂性、策略解释性等多方面问题,成为人工智能领域最具挑战性的难题之一。本文对智能体决策模型训练、模型可解释性、模型演化、策略规则提取等方面进行了研究,但仍存在一些问题,需要进行完善与改进。本节通过对全文内容梳理,总结了以下几点不足和改进方向:

(1) 基于规则的表达方法在规则设计时需要根据环境进行编码，具有较强的环境依赖性，不同环境下编码方式不同，如何设计出一种通用的编码方式，是值得进一步深入研究的方向。

(2) 基于决策树的博弈对抗策略在面对高维数据时非常依赖数据预处理，因为对于决策树模型，叶子节点数与特征数呈指数关系，当特征数越大时，生成的决策树也会越大，合理的数据预处理方法和科学的剪枝策略值得进一步研究。

(3) 本文的策略提取数据是基于强化学习模型与当前环境交互获得的，提取出的策略对当前环境有效，当环境设置不同时，其普适性具有限制，因此，提取出的策略规则泛化性值得进一步的研究。

致谢

一晃已三年，我的研究生生活即将结束，十几年的求学生涯也落入了尾声。回首在东南大学求学的三年来，有过欢笑，也经历过迷茫，收获了知识，也经历了成长，值此毕业论文终稿之际，我想对一路上陪伴我、帮助我的老师、朋友、家人们送上由衷的感谢。

桃李无言，下自成蹊。感谢我的恩师张亚教授，总是用春风细雨般的温柔指导我们的学习和科研，然学生朽木，纵遇良师，未成大器。这三年来，无数次庆幸当时鼓起勇气发送介绍信给张亚老师，成为了她的学生，有幸在做人、做事、做研究上得到她的言传身教，也无数次，因为我的顽劣和愚钝而自责，而张老师却循循善诱、倾尽所能的为我点播与指正，帮助我形成基本的科研规范和解决问题的能力。张老师总是用严谨的科研态度、润物无声的关怀指导与鼓励着我，在我遇到困难时，总是会给我提供新的思路，帮我寻找解决办法，感谢张老师在鼓励我独立探索的同时，用深厚的学术素养和严谨的治学态度引导我前行。无法忘记张老师在百忙之中，对我的问题进行解答，甚至直到深夜。张老师总是牺牲休息时间为我指导论文写作，她的帮助与支持是这篇论文得以成文的重要保障。我衷心地感谢张老师对我的帮助与指导，我一定在今后的学习和工作中加倍努力，争取不辜负她的栽培与教导，也衷心祝愿张老师与家人工作顺利、身体健康、幸福美满。

寸草春晖，难以回报。感谢我的父母与家人对我无微不至的关心与支持，他们的支持是我前进的动力。感谢我开明的父母，在我面临人生抉择时总是在给出我建议后尊重我的所有选择。7年外出求学，他们总是叮嘱我照顾好自己，那一句句叮咛让我在遇困难时心中充满温暖，你们无私的支持与鼓励，是我永远的后盾。

人生海海，幸而相遇。感谢读研期间遇到的每一个人，是他们构建了我丰富多彩的研究生生活。感谢所有的师兄师姐、同门以及师弟师妹们，在研二刚和大家线下见面时，他们总是倾尽所有帮助我尽快融入大家的节奏，带我一起团建，为我答疑解惑，在我的学习和生活中给予了我很多帮助。感谢东无遇到的所有可爱的人儿，我们一起度过了许多美好的时光，也经历了前所未有的快乐，这些美好的经历将成为我永久的回忆。

最后，衷心感激遇见的每一个人，所有经历与相遇，对我而言都是收获和礼物。感谢所有百忙之中抽出时间参与我论文评阅和答辩的专家们，感谢你们的宝贵意见与建议。

参考文献

- [1] 曹雷. 基于深度强化学习的智能博弈对抗关键技术[J]. 指挥信息系统与技术, 2019, 10(05): 1-7.
- [2] 陈希亮, 李清伟, 孙戡. 基于博弈对抗的空战智能决策关键技术[J]. 指挥信息系统与技术, 2021, 12(02): 1-6.
- [3] 孙戡, 李清伟, 徐志雄等. 基于多智能体深度强化学习的空战博弈对抗策略训练模型[J]. 指挥信息系统与技术, 2021, 12(02): 16-20.
- [4] Zhao Q F. Training and retraining of neural network trees[C]//International Joint Conference on Neural Networks(IJCNN). IEEE, 2001: 726-731.
- [5] Ernest N, Carroll D, Schumacher C, et al. Genetic fuzzy based artificial intelligence for unmanned combat aerial vehicle control in simulated air combat missions[J]. Journal of Defense Management, 2016, 06(1): 1-7.
- [6] Dietterich T G. Hierarchical reinforcement learning with the MAXQ value function decomposition[J]. Journal of Artificial Intelligence Research, 2000, 13: 227-303.
- [7] 蒲志强, 易建强, 刘振等. 知识和数据协同驱动的群体智能决策方法研究综述[J]. 自动化学报, 2022, 48(03): 627-643.
- [8] Silver D, Huang A, Maddison C J, et al. Mastering the game of go with deep neural networks and tree search[J]. Nature, 2016, 529(7587): 484-489.
- [9] 叶利民, 龚立, 刘忠. 兵棋推演系统设计与建模研究[J]. 计算机与数字工程, 2011, 39(12): 58-61.
- [10] 张煜东, 吴乐南, 王水花. 专家系统发展综述[J]. 计算机工程与应用, 2010, 46(19): 43-47.
- [11] Burgin G H, Fogel L J, Phelps J P. An adaptive maneuvering logic computer program for the simulation of one-on-one air-to-air combat[J]. General Description. 1975:1-106.
- [12] Goodrich K, Mcmanus J. Development of a tactical guidance research and evaluation system (TGRES)[C]//Flight Simulation Technologies Conference and Exhibit, 1989: 350-355.
- [13] Dorigo M, Maniezzo V, Colorni A. Ant system: Optimization by a colony of cooperating agents[J]. IEEE Transactions on Systems, Man and Cybernetics - Part B, 1996, 26(1): 29-41.
- [14] Kennedy J. Particle swarm optimization[C]//Proceeding of 1995 IEEE International Conference. 2011, 4(8): 1942-1948.
- [15] Karaboga D, Basturk B. A powerful and efficient algorithm for numerical function optimization: Artificial bee colony (ABC) algorithm[J]. Kluwer Academic Publishers, 2007, 39(3): 459-471.
- [16] Yang, She X. Firefly algorithm, stochastic test functions and design optimisation[J]. International Journal of Bio Inspired Computation, 2010, 2(2): 78-84.
- [17] 苏菲, 陈岩, 沈林成. 基于蚁群算法的无人机协同多任务分配[J]. 航空学报, 2008, (S1): 184-191.
- [18] Jevtic A. Distributed bees algorithm for task allocation in swarm of robots[J]. IEEE Systems Journal, 2012, 6(2): 296-304.

-
- [19] Cheng Z, Fan L, Zhang Y. Multi-agent decision support system for missile defense based on improved PSO algorithm[J]. Journal of Systems Engineering and Electronics, 2017, 28(3):514-525.
 - [20] Peng L, Liu H Y. Decision-making and simulation in multi-agent robot system based on PSO-neural network[C]//Proceeding of 2007 IEEE International Conference on Robotics and Biomimetics (ROBIO), 2007:1763-1768.
 - [21] Li A, Spyra O, Perel S, et al. A generalized framework for population based training[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '19), 2019: 1791-1799.
 - [22] Young S R, Rose D C, Karnowski T P, et al. Optimizing deep learning hyper-parameters through an evolutionary algorithm[C]//Proceedings of the Workshop on Machine Learning in High-Performance Computing Environments (MLHPC '15), 2015: 1-5.
 - [23] Salimand T, Ho J, Chen X , et al. Evolution strategies as a scalable alternative to reinforcement learning[J]. arXiv preprint arXiv: 1703.03864, 2017:1-13.
 - [24] Khadka S, Tumer K. Evolution-guided policy gradient in reinforcement learning[C]//Advances in Neural Information Processing Systems, 2018: 1188-1200.
 - [25] Madushani Y, Kasthurirathna D. Incorporating strategy adoption into genetic algorithm enabled multi-agent systems[C]//Proceeding of 2020 IEEE Congress on Evolutionary Computation (CEC). IEEE, 2020: 1-8.
 - [26] Wang S, Zhang C, Zhang J. Evolutionary games and distributed decision-making in a multi-agent system for formation control[C]//Proceeding of 2021 13th International Conference on Computer and Automation Engineering (ICCAE). IEEE, 2021: 43-47.
 - [27] Zhou X, Qin A K, Gong M, et al. A survey on evolutionary construction of deep neural networks[J]. IEEE Transactions on Evolutionary Computation, 2021, 25(5): 894-912.
 - [28] Shao Y, Lin J C W, Srivastava G, et al. Multi-objective neural evolutionary algorithm for combinatorial optimization problems[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 34(4): 2133-2143.
 - [29] Lin K, Jia Z, Li P, et al. Cooperative variable speed limit control using multi-agent reinforcement learning and evolution strategy for improved throughput in mixed traffic[C]//Proceeding of 2023 IEEE International Conference on Smart Mobility (SM). IEEE, 2023: 27-32.
 - [30] 刘昊, 张策, 丁文韬. 基于智能对抗进化的联合火力打击任务规划方法[J]. 兵工学报, 2019, 40(6): 1287-1296.
 - [31] 邢岩, 刘昊, 李保硕. 联合火力打击战法策略的智能进化方法研究[J]. 兵器装备工程学报, 2021, 42(9): 189-195.
 - [32] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.
 - [33] Silver D, Schrittwieser J, Simonyan K, et al. Mastering the game of go without human knowledge[J]. Nature, 2017, 550(7676): 354-359.

-
- [34] Vinyals O, Babuschkin I, Czarnecki W M, et al. Grandmaster level in StarCraft II using multi-agent reinforcement learning[J]. *Nature*, 2019, 575(7782): 350-354.
 - [35] Lowe R, Wu Y I, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[J]. *Advances in Neural Information Processing Systems*, 2017: 1-16.
 - [36] Foerster J, Farquhar G, Afouras T, et al. Counterfactual multi-agent policy gradients[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*, 2018: 1-10.
 - [37] Iqbal S, Sha F. Actor-attention-critic for multi-agent reinforcement learning[C]//*International Conference on Machine Learning*. PMLR, 2019: 2961-2970.
 - [38] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-agent learning based on team reward[C]//*Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems*. 2018: 2085-2087.
 - [39] Hausknecht M, Stone P. Deep recurrent q-learning for partially observable mdps[C]//*Proceeding of 2015 AAAI Fall Symposium Series*. 2015: 29-37.
 - [40] Rashid T, Samvelyan M, De Witt C S, et al. Monotonic value function factorisation for deep multi-agent reinforcement learning[J]. *Journal of Machine Learning Research*, 2020, 21(178): 1-51.
 - [41] Son K, Kim D, Kang W J, et al. Qtran: Learning to factorize with transformation for cooperative multi-agent reinforcement learning[C]//*International Conference on Machine Learning*. PMLR, 2019: 5887-5896.
 - [42] Yang Y, Hao J, Liao B, et al. Qatten: A general framework for cooperative multiagent reinforcement learning[J]. *arXiv preprint arXiv:2002.03939*, 2020: 1-14.
 - [43] Wang J, Ren Z, Liu T, et al. QPLEX: Duplex dueling multi-agent q-learning[C]//*International Conference on Learning Representations(ICLR)*. 2020: 1-27.
 - [44] Kong W, Zhou D, Yang Z, et al. UAV autonomous aerial combat maneuver strategy generation with observation error based on state-adversarial deep deterministic policy gradient and inverse reinforcement learning[J]. *Electronics*, 2020, 9(7): 1121-1144.
 - [45] Bai S, Song S, Liang S, et al. UAV maneuvering decision-making algorithm based on twin delayed deep deterministic policy gradient algorithm[J]. *Journal of Artificial Intelligence and Technology*, 2022, 2(1): 16-22.
 - [46] Urbanowicz R J, Moore J H. Learning classifier systems: A complete introduction, review, and roadmap[J]. *Journal of Artificial Evolution and Applications*, 2009, 2009: 1-25.
 - [47] Friedman J H, Popescu B E. Predictive learning via rule ensembles[J]. *The Annals of Applied Statistics*, 2008: 916-954.
 - [48] Gajowniczek K, Ząbkowski T. Interactive decision tree learning and decision rule extraction based on the ImbTreeEntropy and ImbTreeAUC packages[J]. *Processes*, 2021, 9(7): 1107-1122.
 - [49] Bassel G W, Glaab E, Marquez J, et al. Functional network construction in arabidopsis using rule-based machine learning on large-scale data sets[J]. *The Plant Cell*, 2011, 23(9): 3101-3116.

-
- [50] Holland J H, Reitman J S. Cognitive systems based on adaptive algorithms[J]. ACM Sigart Bulletin, 1977 (63): 49-49.
 - [51] Smith S F. A learning system based on genetic adaptive algorithms[M]. University of Pittsburgh, 1980.
 - [52] Valenzuela-Rendón M. The fuzzy classifier system: A classifier system for continuously varying variables[C]//Proceedings of the 4th International Conference on Genetic Algorithms (ICGA91). 1991: . 346–353
 - [53] Meyer J A, Wilson S W. Lookahead planning and latent learning in a classifier system[C]//From Animals to Animats: Proceedings of the First International Conference on Simulation of Adaptive Behavior. MIT Press, 1991: 316-326.
 - [54] Stolzmann W. Anticipatory classifier systems: An introduction[C]//AIP Conference Proceedings. American Institute of Physics, 2001, 573(1): 470-476.
 - [55] Wilson S W. ZCS: A zeroth level classifier system[J]. Evolutionary Computation, 1994, 2(1): 1-18.
 - [56] Wilson S W. Classifier fitness based on accuracy[J]. Evolutionary Computation, 1995, 3(2): 149-175.
 - [57] Stolzmann W. Anticipatory classifier systems[J]. Genetic Programming, 1998, 98: 658-664.
 - [58] Kim J Y, Cho S B. Exploiting deep convolutional neural networks for a neural-based learning classifier system[J]. Neurocomputing, 2019, 354: 61-70.
 - [59] Preen R J, Bull L. Deep learning with a classifier system: Initial results[J]. arXiv preprint arXiv:2103.01118, 2021: 1-9.
 - [60] Irfan M, Jiangbin Z, Iqbal M, et al. Enhancing learning classifier systems through convolutional autoencoder to classify underwater images[J]. Soft Computing, 2021, 25(15): 10423-10440.
 - [61] Uwano F, Browne W. Hierarchical frames-of-references in learning classifier systems[C]//Proceedings of the Companion Conference on Genetic and Evolutionary Computation. 2023: 335-338.
 - [62] Breiman L. Random forests[J]. Machine Learning, 2001, 45: 5-32.
 - [63] Aitkenhead M J. A co-evolving decision tree classification method[J]. Expert Systems with Applications, 2008, 34(1): 18-25.
 - [64] Chen J, Wang X, Zhai J. Pruning decision tree using genetic algorithms[C]//Proceeding of 2009 International Conference on Artificial Intelligence and Computational Intelligence. 2009, 3: 244-248.
 - [65] Lomax S, Vadera S. A survey of cost-sensitive decision tree induction algorithms[J]. ACM Computing Surveys (CSUR), 2013, 45(2): 1-35.
 - [66] Bratu C V, Savin C, Potolea R. A hybrid algorithm for medical diagnosis [C]//Proceeding of EUROCON 2007-The International Conference on " Computer as a Tool". 2007: 668-673.
 - [67] Rudin C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead[J]. Nature Machine Intelligence, 2019, 1(5): 206-215.
 - [68] Jankowski D, Jackowski K. Evolutionary algorithm for decision tree induction[C]//Proceeding of 13th IFIP International Conference on Computer Information Systems and Industrial Management (CISIM). Springer, 2014: 23-32.

-
- [69] Ernest N, Cohen K, Kivelevitch E, et al. Genetic fuzzy trees and their application towards autonomous training and control of a squadron of unmanned combat aerial vehicles[J]. Unmanned Systems, 2015, 3(03): 185-204.
 - [70] Frosst N, Hinton G. Distilling a neural network into a soft decision tree[J]. arXiv preprint arXiv:1711.09784, 2017: 1-8.
 - [71] Koza J R. Hidden order: How adaptation builds complexity[J]. Artificial Life, 1995, 2(3): 333-335.
 - [72] Zhang, Chengqi, Shichao Zhang. Association rule mining: models and algorithms[M]. Berlin, Heidelberg: Springer Berlin Heidelberg, 2002.
 - [73] Costa V G, Pedreira C E. Recent advances in decision trees: An updated survey[J]. Artificial Intelligence Review, 2023, 56(5): 4765-4800.
 - [74] Holmes J H, Lanzi P L, Stolzmann W, et al. Learning classifier systems: New models, successful applications[J]. Information Processing Letters, 2002, 82(1): 23-30.
 - [75] Rokach L, Maimon O. Top-down induction of decision trees classifiers-a survey[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 2005, 35(4): 476-487.
 - [76] Grajski K A, Breiman L, Di Prisco G V, et al. Classification of EEG spatial patterns with a tree-structured methodology: CART[J]. IEEE Transactions on Biomedical Engineering, 1986 (12): 1076-1086.
 - [77] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
 - [78] 刘潇, 刘书洋, 庄韞恺等. 强化学习可解释性基础问题探索和方法综述[J]. 软件学报, 2023, 34(05): 2300-2316.
 - [79] Bastani O, Pu Y, Solar-Lezama A. Verifiable reinforcement learning via policy extraction[C]// Proceedings of the 32nd International Conference on Neural Information Processing Systems. 2018: 2499-2509.
 - [80] Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning[C]// Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics. JMLR Workshop and Conference Proceedings, 2011: 627-635.

作者简介

- 攻读硕士学位期间发表的论文

- [1] X Li and Y Zhang, Rule Renew Based on Learning Classifier System and Its Application to UAVs Swarm Adversarial Strategy Design[C]//2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2023: 1468-1473.
(EI 收录, 第一作者)

- 攻读硕士学位期间参与的课题

- [1] 科技创新 2030 新一代人工智能重大项目课题, 2021ZD0112702, 安全交互的多智能体人机协作理论与方法, 2021-12 至 2024-11;

毕业/学位论文答辩委员会名单

毕业/学位论文题目		基于规则演化的多智能体博弈对抗策略		
作 者		李萱露		
专 业		电子信息		
研究方向		规则学习与演化		
导 师		张亚		
答 辩 委 员 会 组 成	姓 名	职 称	学科专业	工作单位
	翟军勇 (主席)	教授	控制科学与工程	东南大学
	陈杨杨	教授	控制科学与工程	东南大学
	朱方	教授级高工	电子信息	中兴通讯
	刘杉 (秘书)	讲师(高校)	控制科学与工程	东南大学

备注：

- 1、本表格适用于所有研究生。
- 2、本表格排版在终版毕业/学位论文中，附在毕业/学位论文的最后。